

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ
УЧРЕЖДЕНИЕ ВЫСШЕГО ОБРАЗОВАНИЯ
«РОССИЙСКИЙ ЭКОНОМИЧЕСКИЙ УНИВЕРСИТЕТ ИМЕНИ Г.В. ПЛЕХАНОВА»

Специальный факультет талантливой молодежи «Форсайт» (высшая школа)

«Допустить к защите»

И.о. декана СФТМ «Форсайт»
(высшая школа)
Д.А. Максимов

« ____ » _____ 2026 г.

Выпускная квалификационная работа

Направление 38.04.01 Экономика
Магистерская программа «Data Scientist для экономики»

ТЕМА: «Исследование моделей и методов краткосрочного прогнозирования
доходности криптовалютных фьючерсов с учетом рыночных режимов и
экзогенных факторов»

Выполнил обучающийся Шишов Николай Алексеевич

Группа 15.22Д-Э01/24м

Научный руководитель выпускной
квалификационной работы
Моисеев Никита Александрович
Профессор, д.э.н., уч. звание
"доцент"

(подпись)

Автор _____
(подпись)

Москва - 2026

**Министерство науки и высшего образования Российской Федерации
Федеральное государственное бюджетное
образовательное учреждение высшего образования
«Российский экономический университет имени Г.В. Плеханова»**

АННОТАЦИЯ

выпускной квалификационной работы

Шишова Николая алексеевича

на тему: Исследование моделей и методов краткосрочного прогнозирования доходности криптовалютных фьючерсов с учетом рыночных режимов и экзогенных факторов

Выполнено исследование методов краткосрочного прогнозирования доходности криптовалютных фьючерсов на примере бессрочного контракта ADAUSDT биржи Binance. Предложен метод выбора горизонтов прогнозирования на основе анализа плотности независимых торговых возможностей, позволяющий обосновать использование горизонтов 10, 20 и 30 минут. Сформировано признаковое пространство, включающее ценовые, микроструктурные, календарные и экзогенные факторы, а также проведен многоэтапный отбор наиболее информативных признаков.

Для учета изменения состояния рынка исследованы скрытые марковские модели, позволяющие выделять рыночные режимы и использовать информацию о них при прогнозировании. Выполнено сравнительное исследование статистических моделей точечного и вероятностного прогнозирования, включая линейные регрессионные модели и модели семейства GARCH, а также методов машинного обучения. Для вероятностного моделирования проведен анализ распределений доходностей, подтвердивший целесообразность использования распределения Стьюдента.

Полученные результаты показывают, что при решении задачи краткосрочного прогнозирования ключевое влияние оказывает качество формирования признакового пространства и выбор информативных факторов. На исследуемых данных статистические модели продемонстрировали более высокое качество прогнозирования по сравнению с протестированными моделями машинного обучения.

Ключевые слова: криптовалютные фьючерсы, краткосрочное прогнозирование, временные ряды, машинное обучение, вероятностное

прогнозирование, GARCH, скрытые марковские модели, рыночные режимы, микроструктура рынка, экзогенные факторы.

Автор ВКР

подпись

Шишов Николай Алексеевич

**Ministry of Science and Higher Education of the Russian Federation
Federal State Budgetary Educational Institution of Higher Education
«Plekhanov Russian University of Economics»**

ABSTRACT

of graduation thesis

Shishov Nikolay Alekseevich

This thesis investigates methods for short-term forecasting of cryptocurrency futures returns using the ADAUSDT perpetual futures contract traded on Binance as a case study. A method for selecting forecasting horizons based on the density of independent trading opportunities is proposed, resulting in the selection of 10-, 20-, and 30-minute horizons. A comprehensive feature space consisting of price-based, market microstructure, calendar, and exogenous variables is constructed, followed by a multi-stage feature selection procedure.

Hidden Markov Models are employed to identify market regimes and incorporate regime information into forecasting models. A comparative study of statistical approaches for both point and probabilistic forecasting, including linear regression and GARCH-family models, as well as machine learning algorithms, is conducted. For probabilistic forecasting, the distributional properties of returns are analyzed, demonstrating that the Student's t-distribution provides the best fit to the empirical data.

The results indicate that the quality of the feature space and the selection of informative predictors have a greater impact on forecasting performance than model complexity. On the considered dataset, statistical models consistently outperform the evaluated machine learning approaches across most forecasting quality metrics.

Keywords: cryptocurrency futures, short-term forecasting, time series, machine learning, probabilistic forecasting, GARCH, Hidden Markov Models, market regimes, market microstructure, exogenous factors.

Author *подпись* Shishov Nikolay Alekseevich

СОДЕРЖАНИЕ

ВВЕДЕНИЕ	4
Глава 1. Теоретические основы краткосрочного прогнозирования доходности криптовалютных фьючерсов.....	7
1.1. Особенности рынка криптовалютных фьючерсов как объекта краткосрочного прогнозирования	7
1.2. Обзор исследований в области краткосрочного прогнозирования доходности криптовалютных фьючерсов	10
ГЛАВА 2. Методология исследования краткосрочного прогнозирования доходности криптовалютных фьючерсов.....	14
2.1. Метод оценки привлекательности горизонтов прогноза	14
2.2. Формирование набора признаков.....	16
2.2.1. Ценовые признаки ADAUSDT	16
2.2.2. Признаки потока сделок.....	19
2.2.3. Экзогенные факторы	21
2.3. Методы отбора признаков.....	24
2.4. Методология скрытых марковских моделей (НММ)	26
2.5. Методология статистического моделирования.....	29
2.6. Методология моделей машинного обучения	32
2.7. Методология моделей условной гетероскедастичности	37
ГЛАВА 3. Результаты первичного отбора факторов и построение моделей	41
3.1. Выбор горизонта прогноза	41
3.2. Анализ распределения целевых переменных	48
3.3. Отбор факторов	50
3.4. Сравнение статистических моделей.....	52
3.5. Скрытые марковские модели.....	57
3.6. Сравнение моделей машинногообучения.....	60
ЗАКЛЮЧЕНИЕ.....	70
СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ	72
Научные статьи и материалы конференций.....	72
Интернет-ресурсы, отчеты и статистические материалы.....	76
ПРИЛОЖЕНИЕ А	77
Таблица факторов после первичного отбора.....	77
ПРИЛОЖЕНИЕ Б.....	83
Разбиение признаков на подгруппы	83

ВВЕДЕНИЕ

Рынок криптовалютных производных финансовых инструментов является одним из наиболее динамично развивающихся сегментов мирового финансового рынка. Высокая ликвидность, круглосуточный режим торгов, возможность использования кредитного плеча и значительная внутридневная волатильность делают бессрочные криптовалютные фьючерсы привлекательным объектом исследования задач краткосрочного прогнозирования. Одновременно перечисленные особенности существенно усложняют построение прогнозных моделей вследствие высокой изменчивости рыночных условий, выраженной нестационарности временных рядов и влияния большого числа взаимосвязанных факторов.

Современные исследования в области прогнозирования финансовых временных рядов демонстрируют активное развитие как классических статистических методов, так и алгоритмов машинного обучения. Наряду с историческими доходностями широко используются показатели волатильности, характеристики рыночной микроструктуры, календарные признаки и экзогенная информация, отражающая состояние связанных финансовых рынков. Отдельное внимание уделяется моделям, учитывающим смену рыночных режимов, позволяющим описывать структурные изменения поведения рынка.

Несмотря на значительное количество опубликованных работ, большинство исследований сосредоточено либо на разработке новых моделей прогнозирования, либо на сравнении существующих алгоритмов. Значительно меньше внимания уделяется вопросам формирования информативного признакового пространства, обоснованию выбора горизонта прогнозирования и оценке практической полезности отдельных групп факторов. Кроме того, влияние информации о рыночных режимах и экзогенных признаков на качество краткосрочного

прогнозирования криптовалютных фьючерсов остается исследованным недостаточно.

Актуальность настоящей работы определяется необходимостью комплексного исследования факторов, влияющих на качество краткосрочного прогнозирования доходности криптовалютных фьючерсов, а также сравнительной оценки статистических моделей и методов машинного обучения в условиях высокочастотных рыночных данных.

Объектом исследования является рынок USDT-маржинальных бессрочных криптовалютных фьючерсов биржи Binance на примере контракта ADAUSDT.

Предметом исследования являются модели и методы краткосрочного прогнозирования доходности криптовалютных фьючерсов с использованием ценовых, календарных, микроструктурных и экзогенных факторов, а также информации о рыночных режимах.

Цель исследования заключается в разработке и сравнительном анализе методов краткосрочного прогнозирования доходности криптовалютных фьючерсов с учетом рыночных режимов и экзогенных факторов.

Для достижения поставленной цели решены следующие задачи:

выполнен обзор современных исследований в области прогнозирования финансовых и криптовалютных временных рядов;

разработан метод оценки привлекательности горизонтов прогнозирования и обоснован выбор исследуемых горизонтов;

сформирована система признаков, включающая ценовые, микроструктурные, календарные и экзогенные факторы;

выполнен многоэтапный отбор признаков и исследована информативность отдельных групп факторов;

построены скрытые марковские модели для выделения рыночных режимов и исследована возможность использования информации о режимах в качестве дополнительных признаков;

построены статистические модели точечного и вероятностного прогнозирования;

выполнено исследование моделей машинного обучения;

проведено сравнительное исследование полученных моделей по нескольким горизонтам прогнозирования.

Научная новизна работы заключается в комплексном исследовании влияния различных групп признаков, рыночных режимов и экзогенной информации на качество краткосрочного прогнозирования доходности криптовалютных фьючерсов, а также в разработке метода выбора горизонтов прогнозирования на основе анализа плотности независимых торговых возможностей.

Практическая значимость работы состоит в возможности использования предложенного подхода при построении систем краткосрочного прогнозирования и разработке алгоритмических торговых систем для рынка криптовалютных фьючерсов.

Глава 1. Теоретические основы краткосрочного прогнозирования доходности криптовалютных фьючерсов

1.1. Особенности рынка криптовалютных фьючерсов как объекта краткосрочного прогнозирования

Криптовалюты представляют собой цифровые активы, функционирование которых основано на использовании технологий распределенного реестра и криптографических методов защиты информации. В отличие от традиционных финансовых инструментов большинство криптовалют не имеет централизованного эмитента, а их рыночная стоимость определяется исключительно соотношением спроса и предложения на мировом рынке. За последние годы криптовалютный рынок сформировался как самостоятельный сегмент мировой финансовой системы, включающий спотовые и срочные рынки, широкий круг участников и развитую биржевую инфраструктуру.

Наибольший интерес для активных участников рынка представляют производные финансовые инструменты, в частности бессрочные фьючерсы. В отличие от классических фьючерсных контрактов они не имеют фиксированной даты исполнения, что позволяет удерживать открытые позиции неограниченно долго при соблюдении требований по обеспечению. Для поддержания соответствия между ценой фьючерса и ценой базового актива используется механизм периодических выплат *funding rate*, перераспределяющий средства между держателями длинных и коротких позиций в зависимости от направления отклонения цены контракта от спотового рынка.

Криптовалютные фьючерсы обладают рядом особенностей, отличающих их от производных инструментов традиционных финансовых рынков. Прежде всего, торговля осуществляется непрерывно, без выходных и праздничных дней, вследствие чего на рынке отсутствуют ценовые разрывы, характерные для большинства фондовых площадок. Дополнительной особенностью является высокая внутридневная волатильность, значительно превышающая аналогичные показатели большинства традиционных финансовых инструментов. Кроме того,

криптовалютный рынок характеризуется высокой скоростью распространения информации, значительной долей алгоритмической торговли и быстрым изменением структуры ликвидности.

Перечисленные особенности определяют специфику краткосрочного прогнозирования криптовалютных фьючерсов. Изменение рыночной активности, уровня волатильности и ликвидности сопровождается изменением статистических характеристик временных рядов, вследствие чего зависимости, выявленные на исторических данных, не всегда сохраняются во времени. Это ограничивает возможности моделей, использующих исключительно собственную историю исследуемого ряда, и делает целесообразным привлечение дополнительной информации о состоянии рынка.

В качестве такой информации могут использоваться как внутренние характеристики исследуемого инструмента (ценовые и объемные показатели, лаговые признаки, показатели волатильности), так и внешние факторы, отражающие состояние связанных рынков. Для криптовалютных фьючерсов особое значение имеют показатели рынка Bitcoin, который обладает наибольшей капитализацией и оказывает существенное влияние на динамику большинства альтернативных криптовалют. Кроме того, информативными могут быть календарные признаки, характеризующие время суток, день недели и периоды активности крупнейших мировых торговых площадок.

Другим направлением повышения качества прогнозирования является учет рыночных режимов. Периоды повышенной и пониженной волатильности, устойчивых трендов и бокового движения отличаются статистическими характеристиками временных рядов, вследствие чего эффективность одной и той же модели может изменяться в зависимости от текущего состояния рынка. Поэтому в современных исследованиях все большее внимание уделяется методам, позволяющим идентифицировать рыночные режимы и использовать информацию о них при построении прогнозных моделей.

Таким образом, рынок криптовалютных бессрочных фьючерсов представляет собой сложную динамическую систему, характеризующуюся высокой волатильностью, изменчивостью статистических свойств и существенным влиянием внешних факторов. Перечисленные особенности делают задачу краткосрочного прогнозирования доходности крайне сложной, одновременно создавая предпосылки для применения современных статистических методов, алгоритмов машинного обучения и моделей рыночных режимов.

Эмпирическую основу исследования составляют минутные данные по бессрчному фьючерсному контракту ADAUSDT, обращающемуся на бирже Binance Futures. Выбор данного инструмента обусловлен тем, что криптовалюта Cardano (ADA) на протяжении исследуемого периода входила в число крупнейших цифровых активов по рыночной капитализации, обеспечивая высокий уровень ликвидности и достаточный объем торгов для исследования закономерностей краткосрочной динамики цен.




Рисунок 1 – Изменение места ADA по рыночной капитализации в исследуемом периоде

Источник: составлено автором на основе исторических снимков рынка CoinMarketCap.

На рисунке 1 представлено изменение позиции ADA по рыночной капитализации в период с февраля 2020 по февраль 2026 года. Несмотря на существенные изменения рыночной конъюнктуры, криптовалюта большую часть

времени находилась в первой десятке крупнейших цифровых активов, а в отдельные периоды - в первой пятерке. Это свидетельствует о стабильном положении ADA среди ведущих криптовалют и подтверждает обоснованность выбора данного актива в качестве объекта исследования.

Исследуемый период охватывает данные с февраля 2020 по февраль 2026 года и включает несколько фаз развития криптовалютного рынка, в том числе период активного роста 2020–2021 годов, последующую коррекцию 2022 года, восстановление рынка в 2023–2024 годах и новый этап роста, начавшийся в конце 2024 года. Использование столь продолжительного временного интервала позволяет оценить устойчивость исследуемых моделей в различных рыночных условиях.

1.2. Обзор исследований в области краткосрочного прогнозирования доходности криптовалютных фьючерсов

Современные исследования демонстрируют устойчивый рост интереса к прогнозированию криптовалютных рынков, что связано с развитием методов анализа данных и увеличением доступности высокочастотной рыночной информации. Как отмечается в систематическом обзоре [37], развитие методов прогнозирования прошло путь от классических статистических моделей временных рядов к алгоритмам машинного обучения и современным архитектурам глубоких нейронных сетей. Вместе с тем авторы подчёркивают, что результаты различных исследований трудно сопоставимы вследствие различий в используемых наборах данных, горизонтах прогнозирования, составе признакового пространства и применяемых критериях оценки качества моделей. Кроме того, большинство работ посвящено прогнозированию Bitcoin и использует преимущественно ценовые признаки, уделяя значительно меньше внимания рыночной микроструктуре и экзогенным факторам.

Наиболее полный анализ современных методов прогнозирования и их практического применения представлен в обзоре [31]. Авторы рассматривают статистические модели, методы машинного обучения, глубокие нейронные сети и

гибридные подходы, а также анализируют использование прогнозов при построении торговых стратегий. Одним из ключевых выводов работы является то, что повышение точности прогноза не всегда приводит к улучшению торговых результатов, поэтому качество моделей следует оценивать не только по традиционным метрикам ошибки, но и по способности корректно определять направление движения рынка, устойчивости результатов и учёту транзакционных издержек.

Развитие методов прогнозирования началось с использования классических статистических моделей временных рядов. Модель ARIMA успешно применялась для анализа и прогнозирования динамики цен Bitcoin [39], однако выраженная нестационарность и изменяющаяся во времени волатильность криптовалют обусловили широкое распространение моделей семейства GARCH. Исследования подтверждают эффективность моделей GARCH, EGARCH, GJR-GARCH и APARCH при моделировании условной волатильности криптовалют, анализе асимметрии колебаний и прогнозировании риска [29; 28; 5; 36]. Перспективность совместного использования статистических моделей и методов машинного обучения также подтверждается исследованиями, предлагающими комбинирование моделей GARCH с алгоритмами машинного обучения для повышения качества прогнозирования [22; 15].

Отдельное направление исследований связано с использованием высокочастотных данных и признаков рыночной микроструктуры. Andersen [?] показал преимущества высокочастотных данных при моделировании финансовых рынков, что впоследствии получило развитие применительно к криптовалютам. Последующие исследования посвящены анализу внутрисдневной взаимосвязи между объёмом торгов и доходностью [40], передаче волатильности между криптовалютами [33; 4], влиянию крупнейших криптовалютных бирж на распространение волатильности [2], а также исследованию факторов ликвидности криптовалютных рынков [8]. Полученные результаты подтверждают высокую

информативность признаков микроструктуры рынка при построении краткосрочных прогнозов.

По мере развития вычислительных методов основное внимание исследователей постепенно сместилось к алгоритмам машинного обучения. Выполнены сравнительные исследования ансамблевых методов, искусственных нейронных сетей и других алгоритмов прогнозирования [16; 9; 30; 7]. Наиболее распространёнными архитектурами глубокого обучения являются рекуррентные нейронные сети LSTM, GRU и Bi-LSTM [17], а в последние годы активно развивается применение архитектур Transformer для прогнозирования временных рядов [41]. Одновременно возрастает интерес к использованию альтернативных источников информации, включая анализ тональности сообщений социальных сетей и новостного фона [3; 32].

Обобщить всю рассмотренную литературу можно в таблице 1

Таблица 1 Основные направления исследований в области прогнозирования криптовалютных рынков

Направление исследований	Основные методы	Основные выводы	Ограничения
Статистические модели	ARIMA, ARIMAX	Хорошо описывают линейную структуру временных рядов, используются как базовые модели	Не учитывают изменяющуюся волатильность и нелинейные зависимости
Модели волатильности	GARCH, EGARCH, GJR-GARCH, APARCH	Эффективно моделируют кластеризацию волатильности и асимметрию доходностей	Основное внимание уделяется прогнозу волатильности, а не доходности
Высокочастотный анализ	Realized volatility, микроструктурные показатели	Высокочастотные данные содержат дополнительную информацию о состоянии рынка	Требуют больших объёмов данных и вычислительных ресурсов
Машинное обучение	Random Forest, XGBoost, CatBoost, LightGBM, SVM	Позволяют выявлять сложные нелинейные зависимости между признаками и доходностью	Качество существенно зависит от выбора признаков и настройки гиперпараметров

Глубокое обучение	LSTM, GRU, Bi-LSTM, Transformer	Хорошо работают при моделировании сложной временной структуры	Высокая вычислительная сложность и риск переобучения
Гибридные модели	GARCH+LSTM, GARCH+ML	Сочетают преимущества статистических моделей и методов машинного обучения	Отсутствует единый подход к построению подобных моделей
Альтернативные источники данных	Новости, Twitter/X, настроения инвесторов	Позволяют повысить качество прогнозирования в отдельных исследованиях	Эффект зависит от качества обработки текстовых данных

Источник: составлено автором

Таким образом, современное направление исследований характеризуется постепенным переходом от использования отдельных статистических моделей к комплексным системам прогнозирования, объединяющим методы анализа временных рядов, алгоритмы машинного обучения, признаки рыночной микроструктуры и экзогенные факторы. Вместе с тем обзор литературы показывает, что большинство существующих работ либо сосредоточено на сравнении отдельных моделей, либо рассматривает ограниченный набор признаков и одну криптовалюту, чаще всего Bitcoin. Значительно реже выполняется комплексное сравнение статистических моделей и методов машинного обучения на единых наборах данных с использованием признаков микроструктуры рынка, экзогенных факторов и характеристик рыночных режимов. Именно решение этой задачи является целью настоящего исследования.

ГЛАВА 2. Методология исследования краткосрочного прогнозирования доходности криптовалютных фьючерсов

2.1. Метод оценки привлекательности горизонтов прогноза

Выбор горизонта прогнозирования является одним из ключевых этапов построения моделей краткосрочного прогнозирования доходности. От выбранного временного интервала зависят статистические свойства целевой переменной, информативность используемых признаков и практическая применимость прогнозной модели. Слишком короткие горизонты характеризуются высокой долей случайных ценовых колебаний, тогда как при увеличении горизонта возрастает величина ценовых движений, однако одновременно снижается частота возникновения независимых торговых возможностей. В связи с этим выбор горизонта прогнозирования требует отдельного анализа.

В качестве исходных данных использовались минутные котировки бессрочного фьючерса ADAUSDT. Такая детализация позволяет исследовать доходности в широком диапазоне внутридневных горизонтов - от одной до 120 минут. Использование данных с более крупным временным шагом существенно ограничило бы возможность подобного анализа. Кроме того, расчеты выполнялись отдельно для каждого календарного квартала исследуемого периода, что позволило оценить устойчивость выявленных закономерностей в различных фазах развития криптовалютного рынка.

Расчет доходностей выполнялся следующим образом: для каждой минуты рассчитывалась простая минутная доходность, как относительное изменение цены закрытия текущей и следующей минутой свечи. Доходность на горизонте h определялась накопленным относительным изменением цены за последующие h минут по формуле 1

$$r_t^h = \prod_{i=0}^{h-1} (1 + r_{t+i}) - 1 \quad 1$$

где t - текущий момент времени, r_t^h - доходность через h минут, r_{t+i} - доходность i -ой минуты в окне h .

В работе рассматриваются горизонты от 1 до 120 минут. Для этих горизонтов рассчитывается плотность неперекрывающихся значимых ценовых движений при различных пороговых значениях значимости. На первом этапе для грубой оценки выбраны пороговые значения 0.5%, 1% и 1.5%, для более детального исследования рассматривались значения от 0.2% до 1.5% с шагом в 0.1%.

Необходимость использовать именно не перекрывающиеся окна обусловлена тем, что при последовательном просмотре временного ряда соседние окна длиной h минут в значительной степени перекрываются. Если учитывать каждое такое окно независимо, одно продолжительное ценовое движение будет многократно зарегистрировано как несколько событий, что приведет к завышению оценки их плотности. Для исключения повторного учета одного и того же движения после регистрации события поиск следующего начинается только после завершения текущего интервала длиной h . Таким образом, каждая зарегистрированная торговая возможность соответствует отдельному неперекрывающемуся временному интервалу. Таким образом плотность можно выразить через формулу 2

$$D(h, \theta) = \frac{N(h, \theta)}{T} \quad 2$$

Где θ - заданное пороговое значение, h - длина интервала (горизонт), N - число событий $r_t^h \geq \theta$, T - продолжительность выборки в днях.

У данного подхода есть потенциальная проблема в виде возможного смещения оценки плотности в зависимости от начальной точки просмотра и порядка обработки наблюдений. Для оценки устойчивости алгоритма были проведены два теста для порогов грубой оценки и горизонтов от 1 до 120 минут за весь исследуемый период и за последний календарный квартал этого периода. В первом расчеты повторялись при последовательном смещении начальной точки просмотра временного ряда на 0-120 минут, во втором сравнивались результаты

последовательного просмотра слева направо и справа налево. Полученные результаты показали, что изменение направления просмотра не изменяло положение горизонтов максимальной плотности ни в одном из рассмотренных случаев. Смещение начальной точки приводило лишь к небольшим изменениям оценок плотности (в пределах 2%), однако также не влияло на выбор горизонта, соответствующего максимуму функции плотности.

2.2. Формирование набора признаков

Формирование системы признаков выполнялось исходя из гипотезы о том, что краткосрочная динамика доходности определяется несколькими группами факторов: собственной историей изменения цены, текущим уровнем волатильности, особенностями формирования минутных свечей, состоянием рынка Bitcoin и календарными эффектами. В соответствии с данной гипотезой все признаки были объединены в несколько смысловых групп, каждая из которых отражает отдельный аспект рыночной динамики.

2.2.1. Ценовые признаки ADAUSDT

Основной признак для прогноза логарифмической доходности это лаги этой самой логарифмической доходности, для 10 минут первично берем лаги 1, 2, 3, 5, 10, 15, 30, 60 минут. Считаем также накопленное движение за последние (3, 5, 10, 20, 30, 60) минут по формуле 3

$$R_k = \ln \frac{close_t}{close_{t-k}} \quad 3$$

Где $close_t$ цена закрытия последней известной минуты, $close_{t-k}$ цена закрытия k минут назад.

Для оценки ускорения, с которым меняется цена, посчитаем изменение доходности по формуле 4

$$acc_t = r_t - r_{t-k} \quad 4$$

Где r_t значение доходности последней известной минуты, а k значение лага. Для 10 минут можно рассмотреть $k \in \{3, 5, 10, 20, 30\}$.

В качестве индикатора рыночного режима будем использовать коэффициент Кауфмана, рассчитанный по формуле 5

$$ER = \frac{|close_t - close_{t-k}|}{\sum_{i=1}^k |close_i - close_{i-1}|} \quad 5$$

Где $Close$ цена закрытия минуты, t последняя известная минута, k длина интервала, для которого рассчитывается коэффициент. Этот коэффициент показывает долю направленного движения цены, значения близкие к единице указывают на чистый тренд, близкие к нулю на полное отсутствие тренда. Для 10 минут возьмем $k \in \{5, 10, 20, 30, 60, 90\}$, Дополнением или альтернативой этому коэффициенту может служить Z оценка цен закрытий, z -score может служить показателем не типичности ценовых движений, оцениваемая по формуле 6.

$$zscore_k = \frac{close_t - \mu_k}{\sigma_k} \quad 6$$

В формуле 6 приведена z -score за последние k минут, где μ_k это средняя цена за последние k минут, σ_k это стандартное отклонение цены за последние k минут. Таким образом, чем z -score больше 1, тем не типичнее для данного диапазона было движение цены.

В качестве факторов рассмотрим также скользящее стандартное среднее отклонение доходностей по формуле 7

$$vol_k = \sqrt{\frac{\sum_{i=1}^k (r_i - \bar{r})^2}{k - 1}} \quad 7$$

Где r это минутная доходность, а k это размер скользящего окна.

И сравним его с реализованной волатильностью, оцениваемой по формуле 8

$$RVol_k = \sqrt{\sum_{i=1}^k r_i^2} \quad 8$$

В каждом случае возьмем $k \in \{5, 10, 20, 30, 60\}$

Рассмотрим, как можно дополнить цены закрытий, используя отдельные данные о свечах. Например, можно оценивать так называемые тени свечи, то есть часть ценового движения, которое не было удержано к концу минуты. Все что выше цены закрытия называют верхняя тень, все что ниже это нижняя тень. Сразу нормируем значения, чтобы они не были чувствительны к изменениям масштаба цен. Нормированные значение теней вычисляется по формулам 9 и 10

$$wick_{upper} = \frac{high - \max(open, close)}{high - low} \quad 9$$

$$wick_{lower} = \frac{\min(open, close) - low}{high - low} \quad 10$$

Где $wick_{upper}$ верхняя тень, $wick_{lower}$ нижняя тень, $high$ наибольшая цена в минуте, low наименьшая цена в минуте, $open$ цена открытия, $close$ цена закрытия. Так называемое тело свечи отражает размер доходности этой свечи и уже отражено в целевой переменной, также для свечи можно оценить ее размах и положение точки закрытия относительно максимума и минимума свечи, это можно сделать по формуле 11 нормализованного размаха и формуле 12 относительного положения цены закрытия.

$$range = \ln \frac{high}{low} \quad 11$$

$$closePosition = \frac{close - low}{high - low} \quad 12$$

Все эти признаки описывают геометрию свечи, в качестве факторов считаем их для последних известных 5, 10, 20, 30 и 60 минут.

Отдельный интерес может представлять соотношение свечей, закрывшихся вблизи своего максимума, например те, для которых $closePosition \geq 0.8$, введем коэффициент, показывающий долю таких свечей из общего числа свечей за последние k минут, и назовем его `high_close_ratio`.

Помимо данных о цене в минутных свечах есть объемы, из объемов торгов за минуту можно получить накопленный объем за окно и z-score объема, таким

образом в качестве факторов выбрана сумма объемов за окна в 10, 20, 30 и 60 минут, а также z оценка для этих окон.

2.2.2. Признаки потока сделок

Поток сделок позволяет рассмотреть, как действия отдельных трейдеров привели к результату, наблюдаемому в минутных свечах, были это крупные сделки или много маленьких, как менялось соотношение покупки по рыночной цене с продажей по рыночной цене, какими объемами в среднем торговали участники.

Первое что надо взять как фактор это число сделок в минуту за последние 5, 10, 20 и 30 минут.

Следующее что можно получить из потока сделок это нормализованная дельта агрессии, определяемая формулой 13

$$\Delta V^{norm} = \frac{V^{buy} - V^{sell}}{V^{buy} + V^{sell}} \quad 13$$

Где V^{buy} это суммарный объем сделок в базовой валюте, в которых покупатель не был мейкером, т.е. не размещал заявку на покупку по конкретной цене, а купил по рыночной, V^{sell} это суммарный объем сделок в базовой валюте, в которых покупатель мейкер. Отдельно оценивается дельта крупных сделок, то есть ΔV^{norm} для верхнего квантиля объемов. Обе дельты будем считать для скользящих окон 5, 10, 20, 30 минут. Продолжая тему крупных сделок, рассмотрим, как распределен объем между ордерами с помощью критерия энтропии, определяемого формулой 14

$$H = - \sum p_i * \log p_i \quad 14$$

Где p_i в свою очередь вычисляется по формуле 15

$$p_i = \frac{q_i}{\sum q_i} \quad 15$$

При $H = 0$ весь объем находится в одной сделке, при значении $H = \log n$ весь объем равномерно распределен на n сделок. Для использования в модели можно

нормировать H и взять как фактор $\frac{H}{\log n}$. Аналогично дельте агрессии считаем параметр скользящими окнами в 5, 10, 20, 30 минут. Дополнительно рассмотрим обратный индекс Симпсона, деленным на число сделок внутри рассматриваемого окна, вычисляется он по формуле 16

$$N_{eff} = \frac{1}{n * \sum p_i^2} \quad 16$$

Чем равномернее распределен объем между n сделками, тем ближе N_{eff} к 1, чем выше концентрация объема в отдельных сделках, тем ближе N_{eff} к 0.

Может оказаться полезным средний размер сделки внутри окна, в данном случае объем следует оценивать не в базовой, а в котировочной валюте. Коэффициент рассчитаем по формуле 17

$$ATS = \frac{\sum q}{N} \quad 17$$

Где q объем сделки в котировочной валюте, N это число сделок внутри окна. Считаем его для окон в 5, 10, 20, 30 минут.

Возвращаясь к объемам, для оценки агрессии продавцов или покупателей нужно посчитать дельту агрессии по формуле 18

$$\Delta V_{agr} = V^{buy} - V^{sell} \quad 18$$

Тогда для оценки концентрации давления внутри временного окна рассчитаем коэффициент по формуле 19

$$L = \frac{\Delta V_{end} - \Delta V_{start}}{\Delta V_{total}} \quad 19$$

Где ΔV_{end} это дельта агрессии за последние 20% времени, ΔV_{start} дельта агрессии за первые 80% времени, ΔV_{total} дельта агрессии за все окно. Окна возьмем также 5, 10, 20, 30 минут.

Таким образом показатель L характеризует концентрацию агрессивного торгового давления в заключительной части временного интервала. Высокие значения L указывают на сохранение импульса и повышенную вероятность продолжения движения, тогда как низкие или отрицательные значения могут свидетельствовать об истощении давления и потенциальной фазе поглощения.

2.2.3. Экзогенные факторы

При прогнозе альткоинов нельзя не обращать внимания на поведение первой криптовалюты. Корреляционный анализ показал, что прямая и сильная корреляция между доходностями BTC и ADA есть, но она почти полностью теряется даже при лаге в 1 минуту, это видно на рисунке 2




Рисунок 2 корреляция доходности BTC с лагами ADA

Источник: составлено автором на основе минутных данных Binance Market Data

Такую связь нельзя использовать в модели, но ее наличие очевидно. Валюты связаны, но передача импульса от одной к другой происходит меньше чем за минуту, в такой ситуации не следует отказываться от данных о BTC, следует построить несколько факторов из них. Посчитаем логарифмические доходности BTC за 5, 10, 20, 30, 60 минут, стандартное отклонение логарифмов доходностей по скользящим окнам в 10, 20, 30, 60 минут и коэффициент Кауфмана для окна в 30 и 60 минут.

Второй не менее важной группой экзогенных факторов будут режимы работы бирж и текущее время. Время следует представить как пару синуса и косинуса от времени дня и от дня недели, правила представления приведены в формулах 20, 21, 22 и 23

$$\sin_{hour} = \sin\left(\frac{2\pi t}{1440}\right) \quad 20$$

$$\cos_{hour} = \cos\left(\frac{2\pi t}{1440}\right) \quad 21$$

Где t это целое число минут, прошедших с 00:00 текущего дня

$$\sin_{day} = \sin\left(\frac{2\pi t}{7}\right) \quad 22$$

$$\cos_{day} = \cos\left(\frac{2\pi t}{7}\right) \quad 23$$

Где t это номер дня недели, понедельник 0, воскресенье 6. Отдельно пометим выходные, создадим категориальный признак `is_weekend`.

Для формирования факторов, несущих информацию о часах работы традиционных бирж следует разбить все мировые биржи по временным зонам и взять время активности бирж с самым большим вкладом в торговый объем внутри зоны. Для этого были проанализированы данные всемирной федерации бирж (World Federation of Exchanges, WFE), а именно Value traded (EOB Total) для каждой биржи. Ниже в таблице 1 приведены значения суммарных торговых объемов за 2025 год в миллионах долларах США для крупнейших бирж внутри временной зоны. Отдельно выделены биржи, обеспечивающие около 85% всех торговых объемов, где каждая отдельная биржа составляет не менее 5% от общего объема внутри зоны, прочие же биржи в зоне можно не учитывать при выборе интервалов активности зоны. Из этих бирж выберем те, для которых возможно восстановить точное время работы с учетом всех праздников, выходных и внеплановых прерываний работы за любой временной интервал. Использовать для этого можно python библиотеку `exchange_calendars`.

Таблица 2 объемы торгов крупных традиционных бирж

Биржа	Объем в млн \$ США	кумулятивная доля от общего объема в зоне
Америка		
NYSE	41404536.46	39%
Nasdaq - US	39511198.35	76%
Cboe Global Markets	20134301.38	95%
прочие	5751962.38	100%
всего	106801998.6	
Азия		
Shenzhen Stock Exchange	34551244.05	40%
Shanghai Stock Exchange	24664120.45	69%
Japan Exchange Group	8335408.85	79%
Hong Kong Exchanges and Clearing	5965793.08	86%
прочие	12373511.14	100%
всего	85890077.57	
Европа и Африка		
Euronext	3335008	26%
Cboe Europe	3158381.9	51%
Deutsche Boerse AG	1535131.14	63%
Borsa Istanbul	977524.56	71%
SIX Swiss Exchange	894425.76	78%
Nasdaq Nordic and Baltics	855577.91	84%
прочие	1996220.61	100%
всего	12752269.88	

Источник: составлено автором на основе данных World Federation of Exchanges.




Рисунок 3 Торговые сессии отдельных бирж

Источник: составлено автором с применением python библиотеки exchange_calendars

На рисунке 3 приведена диаграмма часов работы бирж, которые доступны в этой библиотеке, в качестве примера выбран произвольный будний день (среда), было также проверено несколько других дней для гарантии что выбранный день не является исключением.

Руководствуясь данной диаграммой, можно выбрать следующие категориальные признаки: Азия открыта, Свое Europe открыта, вся Европа открыта, США открыты. Ниже на рисунке 4 представлена диаграмма для групп бирж.




Рисунок 4 Торговые сессии групп бирж

Источник: составлено автором с применением python библиотеки `exchange_calendars`

Таким образом все имеющиеся данные превращены в факторы. В общей сложности вышло 126 факторов с учетом всех лагов.

2.3. Методы отбора признаков

Ранее было выделено 126 признаков с учетом всех лаговых переменных и скользящих окон. Скользящие окна разной длительности одного и того же признака перекрывают друг друга, что закономерно приводит к высокой мультиколлинеарности. Часть признаков используются для оценки одних и тех же характеристик рынка, но с несколько разными подходами. Задача последующего анализа - это выявления тех признаков, которые могут быть объяснены другими признаками набора и не улучшают способность всего набора объяснить целевую

переменную. Целевых переменных в работе несколько, а именно логарифмы доходности за последующие 10, 20 и 30 минут. Для каждой цели строятся свои модели и подбирается свой набор признаков. Первый этап отбора признаков осуществляется через оценку изменения коэффициента линейной корреляции Пирсона, коэффициента ранговой корреляции Спирмена, показателя взаимной информации (Mutual Information) и коэффициента дистанционной корреляции. С помощью этих метрик сравним ценность каждого фактора внутри его группы, то есть факторов, образованных по одинаковому или схожему принципу, но для разных периодов времени.

В отличие от коэффициентов корреляции Пирсона и Спирмена, Mutual Information (MI) не предполагает линейного или монотонного характера зависимости и позволяет оценить объем информации, который значения одного признака содержат о значениях другого.

Существует несколько способов оценки взаимной информации. В настоящей работе использован дискретный подход, основанный на предварительном разбиении непрерывных данных на интервалы. Для этого значения обоих рядов разделялись на десять равновероятных интервалов (децилей), после чего каждому наблюдению присваивались номера соответствующих децилей x и y . На основе полученных пар строилась таблица совместных частот, по которой рассчитывался показатель взаимной информации по формуле 24

$$MI(X; Y) = \sum_{x,y} P(x, y) * \ln \frac{P(x, y)}{P(x) * P(y)} \quad 24$$

Где $P(x, y)$ - совместная вероятность попадания наблюдения в соответствующие децили x и y , а $P(x)$ и $P(y)$ - маргинальные вероятности соответствующих децилей.

Использование децилей представляет собой компромисс между точностью оценки и ее устойчивостью. Более крупное разбиение приводит к потере информации, тогда как увеличение числа интервалов повышает чувствительность

оценки к случайным колебаниям выборки. Поскольку целью работы является сравнительный анализ информативности признаков внутри каждой группы, использование десяти интервалов представляется достаточным.

В отличие от коэффициентов корреляции, взаимная информация не имеет фиксированного диапазона значений, поэтому ее абсолютная величина не может интерпретироваться как мера силы связи. Вместе с тем показатель позволяет надежно ранжировать признаки по степени их информативности. В настоящей работе анализировались не только ранги признаков по величине MI , но и абсолютные значения показателя, что позволяло оценить, насколько существенно различается информативность соседних признаков внутри рассматриваемой группы.

Отбор признаков выполнялся отдельно для каждой группы факторов. На первом этапе анализировались коэффициенты корреляции Пирсона, Спирмена, дистанционная корреляция и взаимная информация. Если абсолютное значение коэффициента корреляции не превышало 1 %, соответствующая корреляционная метрика не учитывалась при сравнении признаков. Если ни одна из корреляционных метрик не превышала данного порога, группа признаков оценивалась преимущественно по значениям взаимной информации и дистанционной корреляции. Итоговый набор формировался таким образом, чтобы сохранить признаки, обеспечивающие максимальную информативность по совокупности используемых метрик, при минимально необходимом числе факторов.

2.4. Методология скрытых марковских моделей (НММ)

Одной из характерных особенностей финансовых временных рядов является изменение статистических свойств рынка во времени. Периоды устойчивого роста, снижения и бокового движения различаются не только направлением изменения цены, но и уровнем волатильности, характером торговой активности и степенью выраженности тренда. В результате предположение о неизменности

статистических характеристик временного ряда, лежащее в основе многих моделей прогнозирования, может приводить к снижению качества прогноза.

Одним из наиболее распространённых подходов к описанию подобных изменений являются скрытые марковские модели (Hidden Markov Models, HMM), позволяющие представить наблюдаемый временной ряд как последовательность нескольких скрытых состояний (рыночных режимов). В отличие от методов кластеризации, рассматривающих каждое наблюдение независимо, HMM учитывают временную структуру данных и моделируют вероятности переходов между режимами, что особенно важно при анализе финансовых временных рядов.

Предполагается, что в каждый момент времени рынок находится в одном из конечного множества скрытых состояний

$$S = \{S_1, S_2, \dots, S_N\} \quad 25$$

где N — число рыночных режимов.

Переход между состояниями описывается матрицей вероятностей переходов

$$A = \{a_{ij}\} \quad 26$$

где

$$a_{ij} = P(S_t = j \mid S_{t-1} = i) \quad 27$$

Таким образом, вероятность следующего состояния определяется только текущим состоянием системы и не зависит от более ранней истории наблюдений, что соответствует марковскому свойству.

В каждом скрытом состоянии наблюдается собственное распределение признаков. В настоящей работе предполагается, что условное распределение наблюдаемого вектора признаков описывается многомерным нормальным распределением

$$X_t \mid S_t = i \sim \mathcal{N}(\mu_i, \Sigma_i) \quad 28$$

где

μ_i — вектор средних значений признаков;

Σ_i — ковариационная матрица признаков в режиме i .

Использование полной ковариационной матрицы позволяет учитывать взаимосвязь между признаками внутри каждого режима. Это особенно важно для финансовых временных рядов, поскольку доходность, волатильность, характеристики тренда и показатели рыночной активности тесно коррелированы между собой.

Оценка параметров модели выполняется по историческим данным без предварительной разметки режимов с использованием алгоритма Баума—Уэлша, представляющего собой разновидность ЕМ-алгоритма. На каждой итерации производится оценка вероятностей принадлежности наблюдений скрытым состояниям и последующее уточнение параметров модели до достижения сходимости функции правдоподобия.

После завершения обучения наиболее вероятная последовательность скрытых состояний восстанавливается с использованием алгоритма Витерби, обеспечивающего максимизацию совместной вероятности наблюдаемой последовательности и последовательности скрытых состояний.

В настоящем исследовании скрытые марковские модели используются не как самостоятельный инструмент прогнозирования, а как средство выделения рыночных режимов, информация о которых затем включается в состав объясняющих переменных моделей прогнозирования. Такой подход позволяет учитывать изменение структуры рынка без необходимости строить отдельную модель прогнозирования для каждого режима.

Перед обучением НММ все признаки подвергались стандартизации. Количество скрытых состояний определялось путем перебора моделей с различным числом режимов и последующего сравнения по информационному критерию Байеса (BIC). При окончательном выборе модели учитывалась не только величина BIC, но и интерпретируемость полученных режимов. Слишком большое

число состояний позволяло добиться незначительного уменьшения информационного критерия, однако сопровождалось чрезмерным дроблением сходных рыночных состояний и ухудшением практической интерпретации модели.

После обучения НММ для каждого наблюдения определялись:

- наиболее вероятный рыночный режим;
- вероятности принадлежности каждому режиму;
- продолжительность пребывания в текущем состоянии.

Полученные характеристики использовались как дополнительные признаки при построении моделей краткосрочного прогнозирования доходности криптовалютных фьючерсов.

2.5. Методология статистического моделирования

Целью данного этапа исследования является сравнение нескольких классов линейных статистических моделей, различающихся способом оценки коэффициентов и устойчивостью к мультиколлинеарности и выбросам. Использование нескольких моделей позволяет оценить, насколько применение различных методов регуляризации и робастной оценки параметров влияет на качество краткосрочного прогнозирования доходности криптовалютных фьючерсов.

Все рассматриваемые модели строятся в рамках общей линейной зависимости

$$y_t = \beta_0 + \sum_{i=1}^p \beta_i x_{i,t} + \varepsilon_t \quad 29$$

Где y_t - прогнозируемая логарифмическая доходность, x_i - значения признаков, β_i - оцениваемые коэффициенты модели, ε_t - случайная ошибка.

Различие между моделями заключается исключительно в способе оценки коэффициентов.

Базовой статистической моделью исследования является линейная регрессия, параметры которой оцениваются методом наименьших квадратов (Ordinary Least Squares, OLS). Коэффициенты определяются путем минимизации суммы квадратов ошибок

$$\min_{\beta} \sum_{i=1}^n (y_i - \hat{y}_i)^2 \quad 30$$

Метод OLS обладает высокой интерпретируемостью, позволяет непосредственно оценить влияние каждого признака на прогнозируемую доходность и широко используется как базовая модель при сравнении алгоритмов прогнозирования финансовых временных рядов.

Однако эффективность метода существенно снижается при наличии сильной мультиколлинеарности признаков, а также при присутствии выбросов, характерных для высокочастотных финансовых данных.

Для уменьшения влияния мультиколлинеарности используется гребневая регрессия (Ridge Regression). В отличие от OLS функция потерь дополняется штрафом на величину коэффициентов

$$\min_{\beta} \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p \beta_j^2 \right) \quad 31$$

Где λ - коэффициент регуляризации.

L2-регуляризация препятствует чрезмерному росту коэффициентов при высокой корреляции факторов, уменьшая дисперсию оценок и снижая риск переобучения. При этом все признаки сохраняются в модели.

В модели Lasso используется L1-регуляризация

$$\min_{\beta} \left(\sum_{i=1}^n (y_i - \hat{y}_i)^2 + \lambda \sum_{j=1}^p |\beta_j| \right) \quad 32$$

Особенностью данного метода является возможность автоматического исключения части признаков за счет обращения соответствующих коэффициентов в ноль.

Поскольку первоначальный набор признаков содержит большое количество взаимосвязанных переменных, использование Lasso позволяет одновременно выполнять построение модели и дополнительный отбор факторов.

Elastic Net объединяет преимущества Ridge и Lasso посредством совместного использования L1- и L2-регуляризации

$$\min_{\beta} (RSS + \lambda(\alpha \|\beta\|_1 + (1 - \alpha) \|\beta\|_2^2)) \quad 33$$

Где α определяет баланс между двумя типами регуляризации.

Использование Elastic Net особенно эффективно при наличии групп сильно коррелированных признаков, когда применение Lasso может приводить к случайному выбору лишь одного представителя группы.

Финансовые временные ряды характеризуются тяжелыми хвостами распределения и периодическим возникновением экстремальных ценовых движений. В таких условиях квадратичная функция потерь OLS становится чрезмерно чувствительной к отдельным наблюдениям.

Для повышения устойчивости оценок в исследование включена робастная регрессия Хубера (Huber Regression). Вместо квадратичной функции используется функция потерь

$$L_{\delta}(r) = \begin{cases} \frac{1}{2}r^2, & |r| \leq \delta, \\ \delta\left(|r| - \frac{1}{2}\delta\right), & |r| > \delta, \end{cases} \quad 34$$

Где r - ошибка прогноза.

При небольших ошибках модель эквивалентна обычной линейной регрессии, а влияние крупных выбросов существенно уменьшается.

Это делает регрессию Хубера перспективной для задач прогнозирования доходностей криптовалют, распределения которых характеризуются высокой асимметрией и тяжелыми хвостами.

Для всех рассматриваемых моделей обучение выполнялось отдельно для горизонтов прогнозирования 10, 20 и 30 минут.

Построение моделей осуществлялось поэтапно. На первом этапе использовались только авторегрессионные признаки. Затем последовательно добавлялись ценовые характеристики, признаки микроструктуры рынка, факторы рынка Bitcoin и календарные признаки. Такой подход позволяет оценить вклад каждой группы факторов в качество прогнозирования.

Для предотвращения чрезмерного роста числа моделей после завершения каждого этапа выполнялся промежуточный отбор. Модели ранжировались по двум независимым критериям. Первый критерий был ориентирован на минимизацию ошибки прогнозирования (MAE и RMSE), второй - на максимизацию точности определения направления движения цены (Direction Accuracy). В случае равенства показателей предпочтение отдавалось модели, использующей меньшее число признаков.

В результате к следующему этапу переходило не более шести моделей, что обеспечивало последовательное сокращение пространства рассматриваемых комбинаций признаков без существенной потери качества прогнозирования.

2.6. Методология моделей машинного обучения

Наряду со статистическими методами в исследовании рассматриваются современные алгоритмы машинного обучения, позволяющие описывать сложные нелинейные зависимости между признаками и прогнозируемой доходностью. В отличие от линейных моделей, предполагающих аддитивный характер влияния факторов, методы машинного обучения способны автоматически выявлять взаимодействия признаков, учитывать нелинейные закономерности и строить более сложные зависимости между входными переменными и целевой функцией.

В работе рассматриваются как модели точечного прогнозирования, оценивающие математическое ожидание будущей доходности, так и вероятностные модели, формирующие прогнозное распределение случайной величины. Такой подход позволяет сравнить не только точность прогнозирования ожидаемого значения доходности, но и качество оценки неопределенности прогноза.

Для всех рассматриваемых моделей использовались одинаковые обучающие и тестовые выборки, сформированные для горизонтов прогнозирования 10, 20 и 30 минут. Все модели обучались на одинаковых наборах признаков без индивидуального подбора гиперпараметров, что обеспечивало корректность сравнения различных алгоритмов между собой и со статистическими моделями. Целью эксперимента являлась сравнительная оценка различных архитектур машинного обучения, а не поиск оптимальной конфигурации каждой модели.

Одной из основных моделей исследования является CatBoost (Categorical Boosting) — алгоритм градиентного бустинга над ансамблем решающих деревьев. В отличие от классических методов градиентного бустинга, CatBoost использует симметричную структуру деревьев и специальную процедуру построения последовательностей обучения, уменьшающую смещение, возникающее при вычислении статистик по обучающей выборке.

Пусть итоговая модель состоит из ансамбля деревьев решений

$$F(x) = \sum_{m=1}^M \eta f_m(x) \quad 35$$

Где $f_m(x)$ - очередное дерево решений, M - число деревьев, η - скорость обучения.

На каждой итерации новое дерево строится таким образом, чтобы минимизировать функцию потерь относительно ошибок предыдущего ансамбля.

Основными преимуществами CatBoost являются высокая устойчивость к мультиколлинеарности признаков, способность учитывать сложные нелинейные зависимости и сравнительно небольшая чувствительность к предварительной настройке гиперпараметров. Благодаря этим свойствам алгоритм широко применяется при решении задач прогнозирования финансовых временных рядов.

В настоящем исследовании использовались три модификации CatBoost. Для построения точечного прогноза применялась модель с функцией потерь RMSE. Для параметрического вероятностного прогнозирования использовалась модификация RMSEWithUncertainty, одновременно оценивающая математическое ожидание и стандартное отклонение условного распределения. Кроме того, исследовалась квантильная модификация CatBoost (MultiQuantile), позволяющая непосредственно прогнозировать несколько условных квантилей распределения доходности.

Вторым представителем ансамблевых методов является алгоритм LightGBM (Light Gradient Boosting Machine). Как и CatBoost, он относится к семейству градиентного бустинга над деревьями решений, однако использует иной механизм построения деревьев.

В отличие от классического подхода, при котором дерево развивается одновременно по всем листьям одного уровня, LightGBM применяет стратегию leaf-wise growth. На каждой итерации разделяется лист, обеспечивающий максимальное уменьшение функции потерь, что позволяет быстрее повышать точность модели при одинаковом числе деревьев.

Дополнительным преимуществом LightGBM является использование гистограммного алгоритма поиска разбиений, существенно ускоряющего обучение на больших выборках.

Благодаря высокой вычислительной эффективности и способности описывать сложные нелинейные зависимости алгоритм широко применяется при решении задач анализа высокочастотных финансовых данных.

В работе исследовались две модификации LightGBM: регрессия со среднеквадратичной функцией потерь (RMSE) и квантильная регрессия для построения вероятностного прогноза.

Дополнительно в исследование был включен алгоритм XGBoost (Extreme Gradient Boosting), являющийся одним из наиболее распространенных представителей градиентного бустинга над деревьями решений. В отличие от LightGBM, использующего стратегию роста дерева по листьям, XGBoost применяет более консервативную стратегию построения деревьев по уровням (level-wise growth) и включает развитые механизмы регуляризации, снижающие риск переобучения. В настоящей работе XGBoost использовался для решения задачи точечного прогнозирования и рассматривался как дополнительная модель семейства градиентного бустинга.

Точечный прогноз отражает только наиболее вероятное значение будущей доходности и не позволяет оценить неопределенность прогноза. В условиях высокой волатильности криптовалютных рынков практический интерес представляет построение полного прогнозного распределения.

Для этой цели используются модели квантильной регрессии CatBoost и LightGBM. Вместо прогнозирования математического ожидания такие модели оценивают условные квантили распределения

$$Q_{\tau}(y | x) \tag{36}$$

Где τ - уровень квантили.

Обучение выполняется посредством минимизации функции pinball loss

$$L_{\tau}(y, \hat{y}) = \begin{cases} \tau(y - \hat{y}), & y \geq \hat{y}, \\ (\tau - 1)(y - \hat{y}), & y < \hat{y}. \end{cases} \tag{37}$$

В работе одновременно прогнозировались квантили уровней 0,05, 0,25, 0,50, 0,75 и 0,95, что позволяло получать медианный прогноз и строить 90%-й прогнозный интервал доходности.

Для параметрического вероятностного прогнозирования использовалась модель CatBoost RMSEWithUncertainty. В отличие от квантильной регрессии, непосредственно оценивающей отдельные квантили распределения, данная модификация прогнозирует параметры условного нормального распределения будущей доходности

$$y | x \sim N(\mu(x), \sigma^2(x))$$

В процессе обучения модель одновременно оценивает условное математическое ожидание $\mu(x)$ и стандартное отклонение $\sigma(x)$. Полученные параметры позволяют вычислять вероятность реализации различных значений доходности, строить прогнозные интервалы и оценивать качество вероятностного прогноза с использованием отрицательного логарифма правдоподобия.

Следует отметить, что рассмотренные вероятностные модели используют различные подходы к описанию неопределенности. Квантильная регрессия не предполагает конкретной формы распределения и восстанавливает его отдельные квантили непосредственно по данным. Модель RMSEWithUncertainty, напротив, предполагает условное нормальное распределение прогнозируемой величины. Использование обоих подходов позволило сравнить параметрические и непараметрические методы вероятностного прогнозирования.

В отличие от статистических моделей, для которых выполнялся последовательный отбор спецификаций, модели машинного обучения обучались с параметрами, близкими к рекомендуемым по умолчанию, без проведения полного поиска гиперпараметров. Такой подход позволял существенно сократить вычислительные затраты и сосредоточиться на сравнительной оценке различных архитектур. Все модели обучались на одинаковых обучающих выборках и одинаковых наборах признаков, а их качество оценивалось с использованием единого набора метрик, включавшего показатели точечного и вероятностного прогнозирования, что обеспечивало корректное сравнение алгоритмов машинного обучения между собой и со статистическими моделями.

2.7. Методология моделей условной гетероскедастичности

Одной из характерных особенностей финансовых временных рядов является изменчивость уровня волатильности во времени. Для доходностей криптовалют характерны периоды относительно спокойного поведения рынка, сменяющиеся периодами резкого роста колебаний цен. Такое явление известно как кластеризация волатильности и означает, что большие изменения цены имеют тенденцию следовать за большими изменениями, а небольшие - за небольшими.

Классические линейные модели предполагают постоянную дисперсию случайной ошибки, что плохо соответствует свойствам финансовых временных рядов. Для описания изменяющейся во времени условной дисперсии широко используется семейство моделей Generalized Autoregressive Conditional Heteroskedasticity (GARCH).

Пусть логарифмическая доходность представлена в виде

$$r_t = \mu_t + \varepsilon_t \quad 40$$

Где r_t - наблюдаемая логарифмическая доходность, μ_t - условное математическое ожидание, ε_t - случайная ошибка.

Предполагается, что

$$\varepsilon_t = \sigma_t z_t \quad 41$$

Где z_t - независимая случайная величина с нулевым средним и единичной дисперсией, σ_t^2 - условная дисперсия, изменяющаяся во времени.

Таким образом, основной задачей моделей семейства GARCH является моделирование динамики условной дисперсии σ_t^2 , отражающей текущий уровень рыночной волатильности.

В настоящем исследовании рассматриваются четыре наиболее распространённые модификации моделей GARCH, отличающиеся способом

описания динамики условной дисперсии и учетом асимметричного влияния положительных и отрицательных ценовых изменений.

Базовой моделью исследования является модель GARCH(1,1), предложенная Боллерселевом как развитие модели ARCH Энгла.

Условная дисперсия описывается выражением

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad 42$$

Где $\omega > 0$ - постоянная составляющая, α - влияние последнего квадрата ошибки, β - влияние предыдущего значения условной дисперсии.

Модель предполагает симметричное влияние положительных и отрицательных изменений доходности: величина условной дисперсии зависит только от квадрата ошибки, а не от её знака.

Несмотря на простоту, GARCH(1,1) остается одной из наиболее широко используемых моделей прогнозирования финансовой волатильности и применяется в качестве базового ориентира при сравнении более сложных модификаций.

В исследовании модель реализована с параметрами

$$\text{vol} = \text{"GARCH"} \quad p = 1 \quad q = 1$$

Одним из ограничений классической модели GARCH является невозможность описания асимметричной реакции рынка на положительные и отрицательные ценовые изменения.

Для устранения этого недостатка используется экспоненциальная модель GARCH (EGARCH), в которой моделируется логарифм условной дисперсии

$$\ln(\sigma_t^2) = \omega + \beta \ln(\sigma_{t-1}^2) + \alpha \left(\frac{|\varepsilon_{t-1}|}{\sigma_{t-1}} - E \left[\frac{|\varepsilon|}{\sigma} \right] \right) + \gamma \frac{\varepsilon_{t-1}}{\sigma_{t-1}} \quad 43$$

Параметр γ характеризует асимметрию реакции волатильности на изменения доходности. Если его значение статистически отличается от нуля, положительные

и отрицательные ценовые движения оказывают различное влияние на будущую волатильность.

Использование логарифма условной дисперсии автоматически обеспечивает её положительность без необходимости накладывать ограничения на значения коэффициентов модели.

В исследовании использовалась конфигурация

vol="EGARCH" p = 1, o = 1, q = 1

Другим способом учета асимметрии является модель GJR-GARCH, предложенная Глостеном, Джаганнатаном и Ранклом.

Условная дисперсия определяется выражением

$$\sigma_t^2 = \omega + \alpha \varepsilon_{t-1}^2 + \gamma I_{t-1} \varepsilon_{t-1}^2 + \beta \sigma_{t-1}^2 \quad 44$$

где

$$I_{t-1} = \begin{cases} 1, & \varepsilon_{t-1} < 0, \\ 0, & \varepsilon_{t-1} \geq 0. \end{cases} \quad 45$$

Дополнительный параметр γ позволяет отрицательным доходностям оказывать более сильное влияние на будущую волатильность по сравнению с положительными изменениями аналогичной величины.

Такой эффект широко наблюдается на традиционных финансовых рынках и известен как эффект рычага (leverage effect). Несмотря на отсутствие классической структуры капитала у криптовалют, исследования показывают, что асимметрия реакции волатильности может проявляться и на криптовалютных рынках.

В настоящей работе использовалась конфигурация

vol="GARCH" p = 1, o = 1, q = 1

Наиболее общей моделью среди рассматриваемых является модель APARCH (Asymmetric Power ARCH).

Её особенностью является одновременный учет асимметрии и возможности оценки степени, в которой моделируется условная дисперсия.

Модель записывается в виде

$$\sigma_t^\delta = \omega + \alpha(|\varepsilon_{t-1}| - \gamma\varepsilon_{t-1})^\delta + \beta\sigma_{t-1}^\delta \quad 46$$

Где δ - оцениваемый степенной параметр, γ - коэффициент асимметрии.

При различных значениях параметра δ модель способна адаптироваться к различным особенностям распределения доходностей, благодаря чему APARCH рассматривается как одна из наиболее универсальных моделей семейства GARCH.

Использование дополнительного степенного параметра делает модель более гибкой по сравнению с классическими модификациями, однако одновременно увеличивает число оцениваемых параметров и вычислительную сложность обучения.

В исследовании использовалась конфигурация

`vol="APARCH" p = 1, o = 1, q = 1.`

Все модели семейства GARCH обучались независимо для горизонтов прогнозирования 10, 20 и 30 минут на одинаковых обучающих выборках. Для обеспечения сопоставимости результатов во всех случаях использовались модели первого порядка, что соответствует наиболее распространённой конфигурации GARCH(1,1), рекомендуемой в большинстве исследований финансовых временных рядов. Использование одинаковых порядков авторегрессии условной дисперсии позволяет сравнивать влияние различных способов моделирования волатильности при неизменной сложности модели.

Полученные оценки условной дисперсии использовались для формирования прогнозов волатильности и последующего сравнения моделей по единой системе метрик качества.

ГЛАВА 3. Результаты первичного отбора факторов и построение моделей

3.1. Выбор горизонта прогноза

При рассмотрении плотности значимых ценовых движений ADAUSDT на разных горизонтах прогноза метод, описанный в методологии, был применен еще к 8 крупнейшим по капитализации на момент 01.02.2026 года криптовалютам по данным аналитической платформы coinmarketcap.com, за исключением стейблкоинов. Это позволило не только оценить плотность значимых движений ADAUSDT, но и проверить сохраняются ли выявленные закономерности для других валют.

Для каждого инструмента рассчитывалось среднее число неперекрывающихся ценовых движений в день, абсолютная доходность которых превышала пороговые значения 0.5%, 1.0% и 1.5%. Полученные зависимости представлены на рисунке 5.

Для всех исследуемых криптовалют наблюдается качественно одинаковая форма функции плотности. На малых горизонтах увеличение длительности интервала сопровождается быстрым ростом числа неперекрывающихся ценовых движений, превышающих заданный порог. После достижения максимума дальнейшее увеличение горизонта приводит к постепенному снижению плотности событий.




Рисунок 5 Плотность ценовых движений заданной величины на различных горизонтах прогнозирования (среднее за 2020–2026 гг.)

Источник: составлено автором




Рисунок 6 Плотность ценовых движений заданной величины на различных горизонтах прогнозирования (среднее за 2020–2026 гг.)

Источник: составлено автором




Рисунок 7 Плотность ценовых движений заданной величины на различных горизонтах прогнозирования (среднее за 2020–2026 гг.)

Источник: составлено автором

Для порога 0.5 % максимальная плотность достигается преимущественно на горизонтах 5-10 минут, тогда как для порога 1.0 % максимум смещается в диапазон 15-30 минут. При дальнейшем увеличении порога до 1.5 % наиболее плотные области располагаются уже на горизонтах порядка 30-60 минут. Наиболее высокие значения плотности наблюдаются для SOLUSDT и DOGEUSDT, тогда как BTCUSDT характеризуется минимальной плотностью неперекрывающихся движений практически на всем диапазоне исследуемых горизонтов. При этом для всех криптовалют сохраняется одна и та же последовательность фаз: быстрый рост, достижение максимума и последующее плавное снижение.

Для практического применения критерия больший интерес представляет не единственная точка максимума, а диапазон горизонтов, на которых плотность неперекрывающихся ценовых движений остается близкой к максимальной. Для каждого инструмента был определен интервал, в пределах которого плотность составляет не менее 95% от максимального значения (таблица 2).

Таблица 3 Диапазоны горизонтов, соответствующие 95 % максимальной плотности неперекрывающихся ценовых движений

фьючерс	Пороговое значение		
	0.5%	1%	1.5%
ADAUSDT	5-11 минут	13-34 минут	24-69 минут
BCHUSDT	6-13 минут	14-40 минут	27-84 минут
BNBUSDT	6-16 минут	16-49 минут	33-107 минут
BTCUSDT	9-24 минут	24-80 минут	57-120 минут
DOGEUSDT	4-9 минут	7-26 минут	13-43 минут
ETHUSDT	7-16 минут	19-51 минут	38-109 минут
SOLUSDT	4-9 минут	11-28 минут	21-55 минут
TRXUSDT	5-12 минут	12-37 минут	20-78 минут
XRPUSDT	4-11 минут	10-30 минут	16-61 минут
Средняя ширина	7.9 минут	27.7 минут	53 минуты

Источник: составлено автором

В таблице явно выделяется BTCUSDT, показывая более широкий диапазон для всех пороговых значений, для всех фьючерсов наблюдается рост ширины диапазонов с ростом порогового значения.

До настоящего момента зависимость плотности неперекрывающихся движений рассматривалась отдельно для каждого порогового значения. Для комплексного анализа влияния горизонта прогнозирования и величины ценового движения были построены поверхности плотности в координатах «горизонт - порог» с шагом порогового значения 0.1%. На рисунке 6 представлены поверхности плотности неперекрывающихся ценовых движений для исследуемых криптовалют. Несмотря на существенные различия в абсолютной плотности событий, форма поверхности для всех инструментов остается сходной.

Во всех случаях максимальная плотность наблюдается при сочетании малых пороговых значений и коротких горизонтов прогнозирования. Увеличение любого из параметров приводит к уменьшению плотности неперекрывающихся событий, однако влияние горизонта и порога проявляется по-разному. При увеличении горизонта снижение плотности происходит постепенно, тогда как повышение порогового значения сопровождается значительно более быстрым уменьшением числа наблюдаемых движений.

Поверхности имеют гладкий характер без выраженных разрывов и локальных экстремумов, что свидетельствует о непрерывном изменении плотности неперекрывающихся ценовых движений в пространстве параметров «горизонт - порог». Полученная картина отражает усредненные закономерности за весь исследуемый период и позволяет определить области, в которых достигается наибольшая плотность неперекрывающихся событий. Однако практическая применимость такого подхода определяется не только формой усредненной поверхности, но и устойчивостью ее характеристик во времени. Если положение области максимальной плотности существенно изменяется под воздействием рыночных условий, задача выбора горизонта не может быть сведена к поиску единственного оптимума на усредненной зависимости. Поэтому на следующем этапе исследования анализируется временная устойчивость выявленных закономерностей.

плотность неперекрывающихся движений: BTCUSDT

плотность неперекрывающихся движений: ADAUSDT





Рисунок 8 Поверхности плотности неперекрывающихся ценовых движений в координатах «горизонт прогнозирования - пороговое значение»

Источник: составлено автором

плотность неперекрывающихся движений: BCHUSDT

плотность неперекрывающихся движений: BNBUSDT





Рисунок 9 Поверхности плотности неперекрывающихся ценовых движений в координатах «горизонт прогнозирования - пороговое значение»

Источник: составлено автором

Для оценки временной устойчивости были рассчитаны оптимальные горизонты отдельно для каждого календарного квартала, после чего построены распределения их значений для всех исследуемых криптовалют (рисунок 7).




Рисунок 10 Поквартальные распределения горизонтов, соответствующих максимальной плотности неперекрывающихся ценовых движений

Источник: составлено автором

Полученные распределения показывают, что устойчивость положения максимума плотности неперекрывающихся ценовых движений существенно зависит от величины рассматриваемого порога. Для порога 0.5 % большинство исследуемых криптовалют характеризуется сравнительно компактными распределениями квартальных максимумов, что свидетельствует об ограниченной изменчивости максимального по плотности горизонта во времени. При увеличении порога до 1.0 % и особенно до 1.5 % разброс квартальных максимумов заметно возрастает практически для всех исследуемых инструментов. В результате

положение максимума перестает концентрироваться в узком диапазоне горизонтов и существенно чаще смещается между различными временными интервалами, что указывает на снижение его временной устойчивости.

Несмотря на высокую нестабильность во времени максимумов у выбранных пороговых значений, сами эти максимумы очень сильно коррелированы друг с другом, на рисунке 8 приведены матрицы корреляций для исследуемых пороговых значений.




Рисунок 11 Матрицы коэффициентов корреляции рядов поквартальных максимумов плотности неперекрывающихся ценовых движений для различных пороговых значений

Источник: составлено автором

Исключением будут BTC, ETH и DOGE, у остальных между собой везде почти единичная корреляция, вышеуказанные криптовалюты имеют сильную связь со всеми на пороговом значении 0.5%, на 1% и 1.5% она значительно ослабевает, особенно между BTC и DOGE, но в целом с остальным набором связь не сильная, но существенная. Такие матрицы корреляций указывают на то, что смещения максимумов плотности происходят в целом на рынке, а не независимо для каждой криптовалюты.

Ключевым выводом проведенного исследования будет то, что криптовалюты имеют схожие функции плотности значимых ценовых движений, максимумы этих функций не устойчивы во времени, однако функция плотности для низкого порогового значения будет иметь ярко выраженный максимум, находящийся в

коротком горизонте. При повышении порога доходности ярко выраженный максимум сглаживается. Хотя сама функция и продолжает иметь максимум, он становится крайне неустойчив и использовать плотность движений как критерий выбора перестает быть целесообразным. Применительно к ADAUSDT в данной работе будет взято три горизонта 10, 20 и 30 минут. Эти горизонты, судя по квартальным средним плотностям, будут периодически рядом с горизонтом максимальной плотности, что может повысить шанс моделей чаще находить значимые ценовые движения, но проверка эффективности такого решения требует отдельного исследования.

3.2. Анализ распределения целевых переменных

Рассмотрим, как распределены значения логарифмов доходностей для выбранных периодов. В таблице 2 приведены основные статистические характеристики логарифмов доходностей

Таблица 4 статистические характеристики логарифмов доходности

Горизонт	Среднее	Стандартное отклонение	асимметрия	эксцесс	p-value критерия Жарка-Бера
10 мин	0.000011	0.004847	-0.814616	88.004613	0.0
20 мин	0.000022	0.006749	-0.659332	66.833919	0.0
30 мин	0.000032	0.008158	-0.855063	57.293172	0.0

Источник: составлено автором

Для всех горизонтов характерна отрицательная асимметрия распределения, что свидетельствует о большей выраженности отрицательных ценовых движений, значения эксцесса существенно превышают 3, характерное для нормального распределения. Результаты критерия Жарка-Бера отвергают гипотезу о нормальности распределения логарифмических доходностей для всех исследуемых горизонтов ($p\text{-value} < 0,001$). Следовательно, предположение о нормальном распределении не может быть принято, что требует дальнейшего анализа формы распределения и выбора более адекватной вероятностной модели.

Исследуем, насколько хорошо различные теоретические распределения описывают эмпирическое распределение логарифмических доходностей. Для

сравнения выбраны нормальное распределение, распределение Стьюдента, распределение Лапласа и обобщенное распределение ошибок (GED). Такой набор позволяет последовательно исследовать влияние различных свойств распределения на качество аппроксимации данных. Нормальное распределение используется в качестве базовой модели, распределение Стьюдента учитывает наличие тяжелых хвостов, характерных для финансовых временных рядов, распределение Лапласа позволяет оценить влияние более высокой концентрации наблюдений вблизи среднего значения и умеренно тяжелых хвостов, а обобщенное распределение ошибок представляет собой более гибкое семейство распределений с регулируемой формой плотности и толщиной хвостов. Совместное рассмотрение этих распределений позволяет определить, какие особенности эмпирического распределения логарифмических доходностей оказывают наибольшее влияние на качество его описания. В качестве непараметрического эталона дополнительно строится ядерная оценка плотности (Kernel Density Estimation, KDE), которая не накладывает априорных ограничений на форму распределения. Сравнение параметрических распределений с оценкой KDE позволяет визуально оценить качество аппроксимации эмпирического распределения и определить, какие его особенности (толщина хвостов, концентрация наблюдений вблизи среднего значения и возможные отклонения от нормальности) воспроизводятся наиболее точно. В таблице 3 приведены результаты сравнения распределений по AIC и BIC

Таблица 5 результаты сравнения распределений

Горизонт	лучший по AIC	лучший по BIC	AIC	BIC
10 мин	Student-t	Student-t	-4.157019e+06	-4.156986e+06
20 мин	Student-t	Student-t	-3.820778e+06	-3.820745e+06
30 мин	Student-t	Student-t	-3.620115e+06	-3.620082e+06

Источник: составлено автором

Распределение Стьюдента по всем критериям оказалось лучшим на всех горизонтах прогноза, на рисунке 10 можно сопоставить эмпирические наблюдения, KDE и распределение Стьюдента для рассматриваемых целевых переменных. Для лучшей визуализации было отброшено по 0.5% распределения с каждой стороны.

Таким образом распределение Стьюдента наиболее точно описывает эмпирическое распределение логарифмических доходностей, поэтому при построении вероятностных моделей в дальнейшем будет использоваться именно оно.




Рисунок 12 сравнение эмпирического распределения и распределения Стьюдента

Источник: составлено автором

3.3. Отбор факторов

Рассмотрим подробнее несколько примеров анализа групп факторов. На рисунке 10 приведено изменение вышеописанных метрик для группы логарифм накопленной доходности.




Рисунок 13 изменение силы связи накопленной доходности с изменением длительности окна

Источник: составлено автором

Из графиков на рисунке 4 видно, что Пирсон и Спирмен максимальны на окне в 30 минут, а МІ и дистанционная корреляция на окне в 60, значит сохраняем только эти два окна, причем для всех целевых функций.

Коэффициент эффективности Кауфмана ADA




Рисунок 14 изменение силы связи коэффициента Кауфмана с изменением длительности окна

Источник: составлено автором

Рисунок 11 интересен своим резким провалом значений МІ и их последующим плавным ростом, тут наиболее перспективны окна в 5 и 90 минут. Корреляция Пирсона достигает максимума на 60 минутах, а Спирмена на 30, но сила линейной связи в целом слаба. МІ достигает максимума на 5 минутах, но проблема этой метрики в том, что для непрерывных величин не представляется возможным оценить в каких пределах она меняется. На рисунке 12 по той же причине игнорируем Пирсона и Спирмена, для всех целевых функций берем окно 5 минут, для целевой функции на 10 и 30 минут берем еще окно в 30 минут, для 20 берем 60 минут.




Рисунок 15 изменение силы связи верхней тени свечи с изменением длительности окна

Источник: составлено автором

В результате отбора был выбран 61 признак. Подробное разделение признаков по целевым переменным можно посмотреть в таблице 1 приложения А.

3.4. Сравнение статистических моделей

Для каждого горизонта была построена группа статистических моделей. Базовая модель, всегда предсказывающая 0, базовая модель, всегда предсказывающая среднее значение по обучающей выборке. Остальные модели перечислены в таблице 5. Для всех моделей, кроме Huber, $\max_iter=5000$, $\text{random_state}=42$, для Huber $\max_iter=1000$, $\varepsilon=1.35$, $\alpha=0.0001$, $\text{tol}=1e-5$.

Таблица 6 перечень рассматриваемых методов статистического моделирования

Обозначение	Название модели
OLS	Линейная регрессия (метод наименьших квадратов)
Ridge $\alpha \in \{0.1, 1, 10\}$	Гребневая регрессия (Ridge-регрессия)

Lasso $\alpha \in \{10^{-4}, 10^{-5}\}$	Lasso-регрессия
ElasticNet $\alpha = 10^{-4}$, L1_ratio=0.5	Elastic Net-регрессия
Huber	Регрессия Хубера (робастная линейная регрессия)

Источник: составлено автором

Модели обучались поэтапно. На нулевой стадии были построены две базовые (baseline) модели. На всех последующих стадиях обучались модели, представленные в таблице 5.

На каждой новой стадии к ранее использовавшимся признакам добавлялась очередная группа факторов, приведенная в таблице 1 приложения А. Внутри каждой стадии группы факторов последовательно разбивались на подгруппы в соответствии с приложением Б, что позволяло оценить вклад отдельных подмножеств признаков в качество прогнозирования.

По завершении каждой стадии для перехода к следующему этапу отбиралось не более шести лучших моделей. Отбор выполнялся с использованием двух независимых критериев, каждый из которых формировал список из трех моделей, после чего итоговый набор определялся как объединение этих списков.

В рамках первого критерия модели ранжировались по величине средней абсолютной ошибки (MAE). При равенстве значений MAE предпочтение отдавалось модели с меньшей среднеквадратичной ошибкой (RMSE), а при дальнейшем равенстве - модели с меньшим числом используемых признаков.

Второй критерий был ориентирован на практическую применимость моделей. В этом случае основным показателем являлась доля случаев, в которых модель правильно определяла направление изменения доходности при абсолютном значении фактической доходности не менее 0.25 %. При равенстве данного показателя предпочтение также отдавалось модели с меньшим числом используемых признаков.

На рисунке 13 приведено изменение оцениваемых при отборе моделей метрик для исследуемых горизонтов. Во всех исследуемых горизонтах

наблюдается одинаковый характер изменения качества моделей при последовательном расширении пространства признаков. Основной прирост достигается за счет включения ценовых факторов, после чего эффект каждой новой группы признаков постепенно уменьшается. Это свидетельствует о том, что наиболее существенная информация о будущей доходности содержится в собственной динамике цены, тогда как микроструктурные, рыночные и календарные признаки преимущественно уточняют уже сформированный прогноз.

Также из графиков видно, что в зависимости от набора факторов различается лучший вид методов моделирования, причем в большинстве случаев на этапе добавления факторов микроструктуры лучшим по MAE оказалась Lasso $\alpha = 10^{-5}$, по RMSE лучшей стала Линейная регрессия, в определении направления всегда лидировал huber, исключением стало MAE для 30 минут, где лучшим методом оказалась Ridge $\alpha = 10$.




Рисунок 16 изменение метрик отбора моделей по этапам отбора

Источник: составлено автором

Для дальнейшего исследования были выбраны модели, сформированные на этапе добавления акторов микроструктуры. Этот выбор обусловлен достижением абсолютного минимума по RMSE на третьем этапе формирования признакового пространства. Несмотря на незначительное дальнейшее снижение MAE и небольшое увеличение точности определения направления движения цены при добавлении признаков микроструктуры, рынка Bitcoin и календарных факторов, улучшение RMSE после третьего этапа отсутствовало. В соответствии с принципом парсимонии предпочтение было отдано моделям с меньшим числом признаков, обеспечивающим сопоставимое качество прогнозирования при более простой структуре и меньшем риске переобучения.

Метрики лучших статистических моделей приведены в таблице 6.

Таблица 7 лучшие статистические модели

Горизонт, мин	Победитель	Число факторов	NRMSE	DA Lift	OOS (R^2)
10	MAE (Lasso)	12	0.994	2,04%	0,011
20	MAE (Lasso)	29	0.991	2,82%	0,018
30	MAE (Ridge)	16	0.986	2,63%	0,027
10	RMSE (OLS)	45	0.991	1,08%	0,018
20	RMSE (OLS)	45	0.987	1,34%	0,026
30	RMSE (OLS)	36	0.985	0,97%	0,03
10	DA (Huber)	25	0.994	2,17%	0,012
20	DA (Huber)	33	0.992	3,18%	0,016
30	DA (Huber)	23	0.993	3,03%	0,015

Источник: составлено автором

Из представленных результатов можно выделить несколько закономерностей.

Во-первых, различия в величине NRMSE между лучшими моделями оказываются весьма незначительными и не превышают 0,9 %. Это свидетельствует о том, что на данном этапе исследования различные критерии отбора приводят к моделям сопоставимого качества с точки зрения относительной ошибки прогнозирования.

Во-вторых, увеличение числа факторов не приводит к пропорциональному улучшению качества модели. Например, модели OLS используют до 45 признаков, тогда как модели Lasso и Ridge достигают практически аналогичного значения NRMSE, опираясь лишь на 12–29 признаков. Это говорит о том, что регуляризация позволяет существенно сократить размерность модели без заметной потери качества.

В-третьих, на горизонтах 20–30 минут наблюдается более высокий прирост точности определения направления движения по сравнению с горизонтом 10 минут. Максимальное значение DA Lift достигает 3,18 % на горизонте 20 минут, тогда как для 10 минут оно не превышает 2,17 %. Это позволяет предположить, что

более длительные горизонты содержат несколько более устойчивую информацию о направлении будущего движения цены.

Наконец, коэффициент OOS R^2 для моделей, оптимизированных по величине ошибки, возрастает с увеличением горизонта прогнозирования и достигает максимального значения 0,03 на горизонте 30 минут. Несмотря на то, что абсолютные значения коэффициента остаются невысокими, данная тенденция указывает на постепенное увеличение доли объяснимой вариации доходности при переходе к более длительным горизонтам.

В целом результаты показывают, что выбор критерия оптимизации оказывает большее влияние на структуру модели и количество используемых факторов, чем на итоговое качество прогнозирования. Различия по NRMSE между лучшими моделями минимальны, поэтому при их сравнении целесообразно учитывать не только точность, но и компактность модели, а также способность корректно определять направление движения цены.

3.5. Скрытые марковские модели

Для выделения краткосрочных режимов цены был проведен подбор гиперпараметров для скрытой марковской модели на следующих факторах: логарифм минутной доходности, накопленная доходность за 30 минут, волатильность за 20 минут, коэффициент Кауфмана за 90 минут и положение цены относительно максимума и минимума внутри 30 минутного скользящего окна.

Выполнялось два перебора гиперпараметров, в первом перебиралось число скрытых режимов от 2 до 6, диагональная и полная ковариационные матрицы, `random_state` от 0 до 19, то есть всего 200 моделей. На рисунке 14 представлено изменение лучших BIC для разного числа состояний и типов матриц.




Рисунок 17 Результаты первого подбора гиперпараметров HMM

Источник: составлено автором

Первичный перебор показал, что для ценовых признаков лучше подходят модели с full covariance: они позволяют учитывать совместное движение доходности, волатильности, эффективности тренда и положения цены в локальном диапазоне. После этого подбор был уточнён на full covariance с расширенным диапазоном числа состояний.

Минимальный BIC склонялся к более сложным моделям с большим числом состояний. Но для коротких периодов такая модель начинает слишком мелко дробить близкие микрорежимы, что ухудшает интерпретируемость и может добавлять шум в downstream-модель. Поэтому финальная конфигурация была выбрана не как максимальная сложность по likelihood, а как устойчивый production-компромисс: GaussianHMM с 4 состояниями, full covariance и фиксированным random_state=15. Статистика определяемых этой моделью состояний приведена в таблице 7

Таблица 8 статистика режимов выбранной краткосрочной НММ модели

Состояние	Доля наблюдений	Кол-во эпизодов	Средняя длительность	Медиана	Максимум
0	34.43%	27750	32.64	23	342
1	30.29%	14539	54.81	25	2724
2	26.05%	18725	36.60	25	489
3	9.22%	5402	44.91	24	2503

Источник: составлено автором

режимы в основном живут десятки минут, что хорошо совпадает с идеей краткосрочной НММ. При этом состояния 1 и 3 имеют длинные хвосты: иногда модель удерживает их на протяжении сотен или даже тысяч минут, но типичный эпизод всё равно около 24-25 минут по медиане.

Помимо выделения краткосрочных режимов была построена более «медленная» НММ модель также на минутных данных, но в качестве факторов были взяты накопленная логарифмическая доходность за 12 часов, реализованная волатильность за 12 часов, коэффициент Кауфмана за 24 часа и позиция цены закрытия текущей минуты относительно максимума и минимума последних 12 часов. Перебор параметров не проводился, было выбрано 4 скрытых режима, диагональная ковариационная матрица (потому что признаки уже агрегированы на длинных окнах и должны были давать более грубое, стабильное разделение режимов без лишней гибкости полной ковариационной матрицы), `random_state=42`, `n_iter=1000`, `tol=1e-5`, `min_covar=1e-2` чтобы дополнительно стабилизировать обучение. Итоговая статистика режимов приведена в таблице 8

Таблица 9 статистика режимов среднесрочной НММ модели

Состояние	Доля наблюдений	Кол-во эпизодов	Средняя длительность	Медиана	Максимум
0	31.46%	4973	199.71	98	2380
1	24.40%	3653	210.83	99	1944
2	29.10%	5685	161.56	80	2401
3	15.04%	1181	401.90	95	12521

Источник: составлено автором

Режимы получились достаточно длительными, чтобы отобразить их на графике закрытий для тестовой выборки. Рисунок 15 иллюстрирует результаты классификации рыночных состояний, полученные с помощью модели скрытых марковских моделей (НММ) с четырьмя состояниями. На графике представлена динамика цены закрытия фьючерса ADAUSDT за период с 1 января по 1 февраля 2025 года, при этом каждой минуте наблюдений соответствует цвет, отражающий наиболее вероятное скрытое состояние, определённое моделью.



Рисунок 15 Результаты первого подбора гиперпараметров НММ

Источник: составлено автором

На рисунке видно, что выделенные режимы обладают высокой временной устойчивостью и сохраняются на протяжении достаточно длительных интервалов, тогда как смена состояния происходит преимущественно в моменты изменения характера рыночной динамики: ускорения тренда, перехода к консолидации или увеличения волатильности. При этом отдельные режимы неоднократно повторяются в разные моменты времени, что подтверждает способность модели выявлять воспроизводимые закономерности поведения рынка, а не уникальные эпизоды исследуемого периода.

3.6. Сравнение моделей машинного обучения

Результаты экспериментов показали, что среди моделей машинного обучения наилучшие значения RMSE на всех исследуемых горизонтах

обеспечивала модель CatBoost RMSEWithUncertainty. Наиболее высокую точность прогнозирования направления изменения цены продемонстрировали квантильные модели LightGBM, тогда как лучшие значения вероятностных метрик (CRPS и качества покрытия доверительных интервалов) были получены квантильными реализациями CatBoost и LightGBM.

Несмотря на это, сопоставление с ранее исследованными статистическими моделями показало отсутствие существенного преимущества методов машинного обучения при решении задачи точечного прогнозирования. По показателю нормированной среднеквадратичной ошибки лучшие статистические модели стабильно превосходили все рассмотренные ML-алгоритмы на горизонтах 10, 20 и 30 минут.

Некоторое преимущество моделей машинного обучения наблюдалось по метрике Direction Accuracy. Максимальный прирост относительно статистических моделей составил около 0,07 процентного пункта для горизонта 10 минут, 0,39 процентного пункта для горизонта 20 минут и 0,24 процентного пункта для горизонта 30 минут. Однако столь небольшое улучшение сопровождалось увеличением ошибки прогнозирования доходности и поэтому не может рассматриваться как свидетельство превосходства ML-подходов.

В то же время результаты вероятностного прогнозирования оказались более обнадеживающими. Квантильные модели обеспечивали адекватную калибровку прогнозных интервалов и демонстрировали конкурентоспособные значения CRPS, что позволяет рассматривать их не столько как средство повышения точности точечного прогноза, сколько как инструмент количественной оценки неопределенности прогнозов и формирования доверительных интервалов. Подобные модели могут использоваться при построении систем управления риском и фильтрации торговых сигналов.

Проведенный эксперимент позволяет сделать вывод, что в рассматриваемой постановке задачи применение моделей машинного обучения без сложной

процедуры настройки гиперпараметров не обеспечивает существенного выигрыша в качестве краткосрочного прогнозирования доходности по сравнению со статистическими моделями. В связи с этим в дальнейшем основное внимание уделяется статистическим моделям как наиболее эффективным средствам точечного прогнозирования, тогда как вероятностные ML-модели рассматриваются в качестве дополнительного инструмента оценки неопределенности прогнозов.

В таблице 10 приведены метрики лучших точечных моделей машинного обучения

Таблица 10 метрики лучших точечных моделей машинного обучения

горизонт	Лучшая модель	Конфигурация	RMSE	NRMSE_zero	MAE	DA 0.25%	OOS R ²
10	CatBoost RMSE	iterations=500, depth=6, learning_rate=0.05, loss_function=RMSE, random_seed=42	0.005280	1.0059	0.002713	0.5089	-0.0118
20	CatBoost RMSE	iterations=500, depth=6, learning_rate=0.05, loss_function=RMSE, random_seed=42	0.007202	1.0045	0.003826	0.5136	-0.0090
30	CatBoost RMSE	iterations=500, depth=6, learning_rate=0.05, loss_function=RMSE, random_seed=42	0.008597	0.9995	0.004669	0.5118	0.0010

Источник: составлено автором

А в таблице 11 лучших вероятностных моделей машинного обучения

Таблица 11 лучшие вероятностные модели машинного обучения

горизонт	Лучшая модель	Конфигурация	RMSE	NRMSE_zero	MAE	DA 0.25%	C R P S	Coverage90	Width90
----------	---------------	--------------	------	------------	-----	----------	---------	------------	---------

10	CatBoost MultiQua ntile	iterations=500, depth=6, learning_rate=0.05, loss_function=MultiQua ntile, alpha=[0.05,0.25,0.50,0. 75,0.95], random_seed=42	0.005267	1.0036	0.002 705	0.5161	0. 00 18 26	0.9035	0.011 37
20	CatBoost MultiQua ntile	iterations=500, depth=6, learning_rate=0.05, loss_function=MultiQua ntile, alpha=[0.05,0.25,0.50,0. 75,0.95], random_seed=42	0.007197	1.0039	0.003 810	0.5281	0. 00 25 76	0.9034	0.015 99
30	CatBoost MultiQua ntile	iterations=500, depth=6, learning_rate=0.05, loss_function=MultiQua ntile, alpha=[0.05,0.25,0.50,0. 75,0.95], random_seed=42	0.008623	1.0025	0.004 651	0.5256	0. 00 31 57	0.9032	0.019 61

Источник: составлено автором




Рисунок 18 агрегированный топ 15 признаков по нормализованной важности

Источник: составлено автором

Представляет интерес сравнение значимости признаков в моделях машинного обучения и наборов признаков, на которых были построены статистические модели. На рисунке 16 для каждого горизонта представлены 15 признаков с наибольшей нормализованной средней значимостью в моделях, позволяющих оценить значимость признаков.

На всех исследуемых горизонтах среди наиболее значимых признаков доминируют показатели, характеризующие собственную динамику цены и волатильности исследуемого актива. Наиболее высокую важность получили реализованная волатильность (`ada_realized_volatility_60m`, `ada_realized_volatility_20m`), стандартное отклонение доходности (`ada_return_std_60m`, `ada_return_std_20m`) и диапазон изменения цены (`ada_log_range_60m`). Это полностью соответствует результатам статистического моделирования, где во все лучшие спецификации входили группы признаков `trend_volatility` или `trend_volatility_efficiency`.

При этом наиболее важными оказались преимущественно признаки с окнами 20–60 минут, тогда как сами горизонты прогнозирования составляли лишь 10–30 минут. Это свидетельствует о том, что для краткосрочного прогнозирования наибольшую информативность имеет не мгновенная изменчивость рынка, а его состояние, накопленное за более длительный период.

Значительный вклад во всех трех горизонтах вносят календарные признаки, прежде всего синусоидальные представления времени суток (`time_of_day_sin`, `time_of_day_cos`). Особенно высокую важность они имеют для горизонтов 20 и 30 минут, где входят в число трех наиболее значимых факторов. Статистические модели также показывали положительный эффект от добавления календарных признаков на поздних этапах отбора, однако итоговые лучшие спецификации чаще останавливались на этапе включения микроструктурных факторов. Таким образом, модели машинного обучения выявили более выраженную нелинейную зависимость между временем суток и будущей доходностью.

Микроструктурные характеристики также стабильно входят в число наиболее информативных признаков. Для всех горизонтов высокую значимость имеют интенсивность торговли (`ada_trades_per_minute_30m`), средний объем сделки (`ada_average_trade_size_quote_30m`), показатель концентрации сделок (`ada_inverse_simpson_norm_30m`) и объем торгов (`ada_volume_sum_20m`, `ada_volume_sum_30m`). Это хорошо согласуется с результатами статистического моделирования, где наилучшие модели для всех горизонтов содержали группы `trades_only`, `all_microstructure`, `concentration_only` или `aggression_concentration`. Следовательно, обе группы моделей независимо подтверждают высокую прогностическую ценность характеристик рыночной микроструктуры.

Экзогенные признаки, характеризующие состояние рынка Bitcoin, также сохраняют устойчивую информативность. Во всех горизонтах среди наиболее значимых признаков присутствуют показатели волатильности Bitcoin (`btc_return_std_30m`), а на горизонте 10 минут также доходность Bitcoin (`btc_log_return_30m`). Несмотря на то что их вклад уступает собственным характеристикам исследуемого актива, результаты подтверждают гипотезу о наличии влияния общего состояния криптовалютного рынка на динамику отдельных альткоинов.

Особый интерес представляет горизонт прогнозирования 20 минут, для которого среди наиболее значимых факторов появились признаки скрытых рыночных режимов (`price_hmm_n4_prob_state_2`, `price_hmm_n4_prob_state_3`). Это свидетельствует о том, что информация о текущем рыночном режиме действительно содержит дополнительный прогностический сигнал. Вместе с тем отсутствие НММ-признаков среди наиболее важных факторов на горизонтах 10 и 30 минут позволяет предположить, что полезность информации о режиме зависит от выбранного горизонта прогнозирования и не является универсальной.

3.7. Построение вероятностных моделей на основе статистических

После определения лучших моделей точечного прогнозирования для каждого горизонта была выполнена оценка возможности построения вероятностного

прогноза на их основе. В качестве базовых моделей использовались лучшие спецификации, отобранные по критериям MAE, RMSE и Direction Accuracy, поскольку они продемонстрировали наименьшую ошибку прогнозирования и наиболее высокую устойчивость на вневыборочных данных.

Поскольку ранее было показано, что распределение логарифмических доходностей криптовалют существенно отличается от нормального и наиболее адекватно описывается распределением Стьюдента, вероятностные модели строились в предположении, что условное математическое ожидание определяется выбранной регрессионной моделью, а случайная составляющая подчиняется одному из распределений семейства GARCH.

Для моделирования условной дисперсии были исследованы несколько представителей семейства GARCH: классическая модель GARCH(1,1), асимметричные модели EGARCH(1,1) и GJR-GARCH(1,1), а также более универсальная модель APARCH(1,1). Во всех случаях в качестве модели среднего использовался прогноз, полученный одной из ранее отобранных линейных моделей (OLS, Ridge, Lasso или Huber), а параметры условной волатильности оценивались по остаткам этих моделей.

Полученное условное распределение использовалось для расчета прогнозной плотности будущей доходности, доверительных интервалов и вероятностей реализации заданных событий. Качество вероятностных моделей оценивалось с использованием метрик отрицательного логарифма правдоподобия (NLL), непрерывной ранговой вероятностной оценки (CRPS), Pinball Loss и качества покрытия прогнозных интервалов.

Такой подход позволил разделить две составляющие задачи прогнозирования. Линейные модели отвечали за прогнозирование условного математического ожидания доходности, тогда как модели семейства GARCH описывали изменяющуюся во времени неопределенность прогноза. Это обеспечивало

возможность непосредственного сравнения различных спецификаций моделей волатильности при неизменной модели среднего и позволяло оценить вклад вероятностного моделирования в повышение качества прогноза.

Статистика лучших вероятностных моделей, построенных в разделе, приведена в таблице 12

Таблица 12 лучшие вероятностные модели

Горизонт	Базовая модель	Лучшая GARCH	Распределение	NLL	CRPS	Coverage90
10	Huber (DA)	GJR-GARCH(1,1)	Student-t	-4.611	0.001664	98.50%
20	Huber (DA)	GJR-GARCH(1,1)	Student-t	-4.314	0.002310	99.29%
30	Huber (DA)	GARCH(1,1)	Student-t	-4.095	0.002828	99.82%

3.8. Сравнение статистических моделей и моделей машинного обучения




Рисунок 19 сравнение качества точечных прогнозов машинного обучения и статистических моделей

Источник: составлено автором

На рисунке 19 сравниваются лучшие ML-модели с лучшими статистическими моделями по двум ключевым метрикам.

Слева показана разница по NRMSE: во всех горизонтах значение положительное, то есть ML-модели хуже статистических. Разрыв составляет примерно 0.008 для 10 минут, 0.012 для 20 минут и 0.013 для 30 минут. Это означает, что по качеству точечного прогноза ML не улучшает результат, а

наоборот дает более высокую нормированную ошибку. Причем ухудшение сохраняется на всех горизонтах.

Справа показана разница по DA lift. Здесь ML дает небольшой выигрыш: около 0.07 п.п. на горизонте 10 минут, около 0.39 п.п. на 20 минутах и около 0.24 п.п. на 30 минутах. Формально это улучшение Direction Accuracy, но его масштаб мал. Оно не компенсирует ухудшение NRMSE и OOS R^2 , особенно с учетом более высокой сложности ML-моделей.

Сравнение лучших статистических и ML-моделей показало, что применение ML-алгоритмов не привело к существенному улучшению качества прогноза. По метрике NRMSE статистические модели стабильно превосходили ML-модели на всех горизонтах прогнозирования. Небольшой прирост Direction Accuracy для ML-моделей наблюдался, однако его величина не превышала долей процентного пункта и не компенсировала ухудшение ошибки прогноза. Поэтому дальнейшее исследование ML-методов в данной работе не проводилось, а основной акцент был перенесен на статистические модели и вероятностное моделирование волатильности.

ML-модели типа CatBoost MultiQuantile дают хорошо откалиброванные интервалы: Coverage90 около 90.3% на всех горизонтах, то есть почти ровно номинальные 90%. Это сильная сторона ML-вероятностных моделей. Но по качеству распределения они уступают статистическим моделям с GARCH: CRPS у ML выше на всех горизонтах.

Сравнение по CRPS:

Таблица 13 лучшие вероятностные модели

Горизонт	Лучшая ML	ML CRPS	Лучшая stat+GARCH	stat+GARCH CRPS
10	CatBoost MultiQuantile	0.001826	MAE Lasso + GJR-GARCH	0.001664

20	CatBoost MultiQuantile	0.002576	DA Huber + GJR- GARCH	0.002310
30	CatBoost MultiQuantile	0.003157	DA Huber + GARCH(1,1)	0.002828

Источник: составлено автором

По NLL также выигрывают статистические модели с GARCH:

Таблица 14 лучшие вероятностные модели

Горизонт	ML NLL	stat+GARCH NLL
10	-4.271548	-4.611189
20	-3.908999	-4.313735
30	-3.621438	-4.095212

Источник: составлено автором

Главный нюанс: у GARCH-интервалов Coverage₉₀ завышен, особенно на горизонте 30 минут: около 99.8% вместо 90%. То есть GARCH дает лучшие CRPS/NLL, но интервалы требуют калибровки. У ML наоборот: интервалы лучше откалиброваны по coverage, но распределение в целом менее точное.

Вероятностные ML-модели обеспечили близкое к номинальному покрытие 90%-интервалов, однако уступили статистическим моделям с GARCH по CRPS и NLL. На горизонтах 10 и 20 минут лучшие результаты показала комбинация статистической модели среднего с GJR-GARCH, а на горизонте 30 минут — комбинация с GARCH(1,1). При этом для GARCH-моделей наблюдалось завышенное покрытие доверительных интервалов, что указывает на необходимость дополнительной калибровки масштаба прогнозной волатильности.

ЗАКЛЮЧЕНИЕ

В работе проведено комплексное исследование методов краткосрочного прогнозирования доходности криптовалютных фьючерсов на примере бессрочного контракта ADAUSDT биржи Binance. Рассмотрены вопросы выбора горизонта прогнозирования, формирования признакового пространства, отбора факторов, выделения рыночных режимов и построения моделей прогнозирования.

На первом этапе предложен метод оценки привлекательности горизонтов прогнозирования, основанный на анализе плотности независимых торговых возможностей. Исследование показало, что увеличение горизонта сопровождается ростом величины ценовых движений, однако одновременно уменьшается частота возникновения независимых торговых возможностей. В результате в качестве наиболее перспективных были выбраны горизонты 10, 20 и 30 минут, обеспечивающие компромисс между величиной ожидаемых ценовых изменений и частотой возникновения торговых сигналов.

Выполнен анализ распределений целевых переменных. Полученные результаты подтвердили наличие тяжелых хвостов и существенного отклонения распределений доходностей от нормального закона. Наилучшее описание эмпирических распределений на всех исследуемых горизонтах обеспечило распределение Стьюдента, что послужило основанием для его использования при построении вероятностных моделей прогнозирования.

Сформирована система признаков, включающая ценовые характеристики, показатели волатильности, признаки рыночной микроструктуры, календарные и экзогенные факторы. Проведенный многоэтапный отбор показал, что наибольший вклад в качество прогнозирования вносят лаговые признаки, показатели волатильности и отдельные характеристики торгового потока. Использование экзогенной информации о рынке Bitcoin и календарных факторов также обеспечивает дополнительное улучшение качества прогнозирования, хотя величина эффекта существенно зависит от выбранного горизонта.

Для учета изменения структуры рынка построены скрытые марковские модели, позволяющие выделять различные рыночные режимы. Полученные результаты показали, что информация о текущем режиме может использоваться как дополнительный источник информации при построении моделей прогнозирования.

Проведено сравнительное исследование статистических моделей и методов машинного обучения. Несмотря на более высокую вычислительную сложность современных алгоритмов машинного обучения, в рассматриваемой задаче они не продемонстрировали устойчивого превосходства над линейными статистическими моделями. Наилучшие результаты точечного прогнозирования были получены моделями линейной регрессии с регуляризацией, тогда как построенные модели машинного обучения уступали им по большинству используемых метрик качества. Аналогичные выводы были получены и при исследовании вероятностных моделей, где классические подходы на основе распределения Стьюдента и моделей семейства GARCH обеспечили более высокое качество прогнозных распределений по сравнению с протестированными альтернативами.

Полученные результаты свидетельствуют о том, что при прогнозировании краткосрочной доходности криптовалютных фьючерсов ключевое значение имеет не столько выбор наиболее сложной модели, сколько качественное формирование признакового пространства, обоснованный выбор горизонта прогнозирования и учет изменяющихся рыночных условий.

Перспективным направлением дальнейших исследований является построение гибридных моделей, объединяющих статистические методы и современные алгоритмы машинного обучения, а также использование более сложных моделей рыночных режимов и дополнительных источников высокочастотной информации.

СПИСОК ИСПОЛЬЗОВАННЫХ ИСТОЧНИКОВ

Научные статьи и материалы конференций

1. Adedokun A. Bitcoin-Altcoin Price Synchronization Hypothesis: Evidence from Recent Data // Journal of Finance and Economics. 2019. Vol. 7, № 4. P. 137–147.
2. Bouri E., Gupta R., Tiwari A. Volatility Connectedness in the Cryptocurrency Market // Journal of International Financial Markets, Institutions and Money. 2021.
3. Bouteska A., Abedin M. Z., Hajek P., Yuan K. Cryptocurrency Price Forecasting – A Comparative Analysis of Ensemble Learning and Deep Learning Methods // International Review of Financial Analysis. 2024. Vol. 92. Article 103055. DOI: 10.1016/j.irfa.2023.103055.
4. Chen J. Analysis of Bitcoin Price Prediction Using Machine Learning // Journal of Risk and Financial Management. 2023. Vol. 16, № 1. Article 51. DOI: 10.3390/jrfm16010051.
5. Derbentsev V. и др. ARIMA, ARFIMA и BART модели для прогнозирования криптовалютных временных рядов. 2019.
6. Easley D., López de Prado M., O’Hara M. Microstructure in the Machine Age // Journal of Financial Economics. 2020. URL: <https://academic.oup.com/rfs/article-abstract/34/7/3316/5868424>
7. Fleischer J. P., Von Laszewski G., Theran C., Parra Bautista Y. J. Time Series Analysis of Cryptocurrency Prices Using Long Short-Term Memory // Algorithms. 2022. Vol. 15, № 7. Article 230. DOI: 10.3390/a15070230.
8. Ibrahim A., Kashef R., Li M., Valencia E., Huang E. Bitcoin Network Mechanics: Forecasting the BTC Closing Price Using Vector Auto-Regression Models Based on Endogenous and Exogenous Feature Variables // Journal of Risk and Financial Management. 2020. Vol. 13, № 9. Article 189. DOI: 10.3390/jrfm13090189.
9. Iqbal M., Iqbal M., Jaskani F., Iqbal K., Hassan A. Time-Series Prediction of Cryptocurrency Market Using Machine Learning Techniques // EAI Endorsed

- Transactions on Creative Technologies. 2021. Vol. 8, № 28. Article 170286. DOI: 10.4108/eai.7-7-2021.170286.
10. Jelinek S., Poledica A., Petrović B., Milošević P. Forecasting Cryptocurrency Time Series Using Fuzzy Transform, Fourier Transform and Fuzzy Inference System // Proceedings of the International Fuzzy Systems Association and the European Society for Fuzzy Logic and Technology (EUSFLAT 2019). Prague : Atlantis Press, 2019. DOI: 10.2991/eusflat-19.2019.88.
 11. Kurniawan K. ARIMA, GARCH и Хольт–Уинтерс модели для прогнозирования криптовалют. 2022.
 12. Kwon D.-H., Kim J.-B., Heo J.-S., Kim C.-M., Han Y.-H. Time Series Classification of Cryptocurrency Price Trend Based on a Recurrent LSTM Neural Network // Journal of Information Processing Systems. 2019. Vol. 15, № 3. P. 694–706. DOI: 10.3745/JIPS.03.0120.
 13. Luo C., Pan L., Chen B., Xu H. Bitcoin Price Forecasting: An Integrated Approach Using Hybrid LSTM-ELM Models // Mathematical Problems in Engineering. 2022. Article ID 2126518. DOI: 10.1155/2022/2126518.
 14. Makarov I., Schoar A. Blockchain Analysis of the Bitcoin Market // NBER Working Paper. 2021.
 15. Sirignano J., Cont R. Universal Features of Price Formation in Financial Markets // Quantitative Finance. 2021.
 16. Sridhar S., Sanagavarapu S. Multi-Head Self-Attention Transformer for Dogecoin Price Prediction // 2021 14th International Conference on Human System Interaction (HSI). IEEE, 2021. P. 1–6. DOI: 10.1109/HSI52170.2021.9538640.
 17. Vidyulatha G., Mounika M., Arpitha N. Cryptocurrency Prediction Model Using ARIMA // Turkish Journal of Computer and Mathematics Education (TURCOMAT). 2020. Vol. 11, № 3. P. 1654–1660.
 18. Yang S. Using ARIMA Model to Analyse and Predict Bitcoin Price // BCP Business & Management. 2022. Vol. 34. P. 1210–1216. DOI: 10.54691/bcpbm.v34i.3161.

19. Eross A., McGroarty F., Urquhart A., Wolfe S. The Intraday Dynamics of Bitcoin // *Research in International Business and Finance*. 2019. Vol. 49. P. 71–81. DOI: 10.1016/j.ribaf.2019.01.008.
20. Alexander C., Heck D. F., Kaeck A. The Role of Binance in Bitcoin Volatility Transmission // *Applied Mathematical Finance*. 2022. Vol. 29(5). P. 391–414. DOI: 10.1080/1350486X.2022.2125885.
21. Brauneis A., Mestel R., Riordan R., Theissen E. Bitcoin Unchained: Determinants of Cryptocurrency Exchange Liquidity // *Journal of Empirical Finance*. 2023. Vol. 71. P. 143–164. DOI: 10.1016/j.jempfin.2022.08.004.
22. Yarovaya L., Zięba D. Intraday Volume-Return Nexus in Cryptocurrency Markets: Novel Evidence from Cryptocurrency Classification // *Research in International Business and Finance*. 2021. Vol. 58. Article 101592. DOI: 10.1016/j.ribaf.2021.101592.
23. Sensoy A., Silva T. C., Corbet S., Tabak B. M. High-Frequency Return and Volatility Spillovers among Cryptocurrencies // *Applied Economics*. 2021. Vol. 53(37). P. 4310–4328. DOI: 10.1080/00036846.2021.1899119.
24. Takaishi T. Time-Varying Properties of Asymmetric Volatility and Multifractality in Bitcoin // *PLoS ONE*. 2021. Vol. 16(2). Article e0246209. DOI: 10.1371/journal.pone.0246209.
25. Apountolas A. Cryptocurrencies Intraday High-Frequency Volatility Spillover Effects Using Univariate and Multivariate GARCH Models // *International Journal of Financial Studies*. 2022. Vol. 10(3). Article 51. DOI: 10.3390/ijfs10030051.
26. Gradojevic N., Kukolj D., Adcock R., Djakovic V. Forecasting Bitcoin with Technical Analysis: A Not-So-Random Forest? // *International Journal of Forecasting*. 2022. Vol. 38(3). P. 1046–1061. DOI: 10.1016/j.ijforecast.2021.08.001.
27. Rodrigues F., Machado M. High-Frequency Cryptocurrency Price Forecasting Using Machine Learning Models: A Comparative Study // *Information*. 2025. Vol. 16(4). Article 300. DOI: 10.3390/info16040300.

28. García-Medina A., Aguayo-Moreno E. LSTM–GARCH Hybrid Model for the Prediction of Volatility in Cryptocurrency Portfolios // *Computational Economics*. 2023. Vol. 63. P. 1067–1092. DOI: 10.1007/s10614-023-10373-8.
29. Naimy V., Haddad O., Fernández-Avilés G., El Khoury R. The Predictive Capacity of GARCH-Type Models in Measuring the Volatility of Crypto and World Currencies // *PLoS ONE*. 2021. Vol. 16(1). Article e0245904. DOI: 10.1371/journal.pone.0245904.
30. Mostafa F., Saha P., Islam M. R., Nguyen N. GJR-GARCH Volatility Modeling under NIG and ANN for Predicting Top Cryptocurrencies // *Journal of Risk and Financial Management*. 2021. Vol. 14(9). Article 421. DOI: 10.3390/jrfm14090421.
31. Bergsli L. Ø., Lind A. F., Molnár P., Polasik M. Forecasting Volatility of Bitcoin // *Research in International Business and Finance*. 2022. Vol. 59. Article 101540. DOI: 10.1016/j.ribaf.2021.101540.
32. Hamayel M. J., Owda A. Y. A Novel Cryptocurrency Price Prediction Model Using GRU, LSTM and bi-LSTM Machine Learning Algorithms // *AI*. 2021. Vol. 2(2). P. 477–496. DOI: 10.3390/ai2040030.
33. Alipour P., Charandabi S. E. Analyzing the Interaction between Tweet Sentiments and Price Volatility of Cryptocurrencies // *European Journal of Business and Management Research*. 2023. Vol. 8(2). P. 211–215. DOI: 10.24018/ejbmr.2023.8.2.1865.
34. Sattarov O., Choi J. Twitter Attribute Classification With Q-Learning on Bitcoin Price Prediction // *IEEE Access*. 2022. Vol. 10. P. 96136–96148. DOI: 10.1109/ACCESS.2022.3205129.
35. Zhao J., Chu F., Xie L., Che Y., Wu Y., Burke A. F. A Survey of Transformer Networks for Time Series Forecasting // *Computer Science Review*. 2025. Vol. 57. Article 100883. DOI: 10.1016/j.cosrev.2025.100883.

Интернет-ресурсы, отчеты и статистические материалы.

36. Binance Academy. Funding Rates Explained. 2026. URL: <https://academy.binance.com/en/articles/what-are-funding-rates-in-crypto-markets>
37. Binance Academy. What Are Perpetual Futures Contracts?. 2026. URL: <https://academy.binance.com/>
38. Binance Futures API Documentation. 2026. URL: <https://developers.binance.com/docs/derivatives/usds-margined-futures>
39. Binance Futures FAQ. 2026. URL: <https://www.binance.com/en/support/faq>
40. CoinMarketCap. Bitcoin Dominance Chart. 2026. URL: <https://coinmarketcap.com/charts>
41. CoinMarketCap. Cryptocurrency Market Capitalization Charts. 2026. URL: <https://coinmarketcap.com/charts>
42. European Central Bank. Crypto-Assets: Implications for Financial Stability. 2022. URL: <https://www.ecb.europa.eu/pub/pdf/scpops/ecb.op223~3ce14e986c.en.pdf>
43. exchange_calendars Documentation. 2025. URL: https://github.com/gerrymanoim/exchange_calendars
44. IMF. Global Financial Stability Report: Crypto Ecosystem and Financial Stability Challenges. 2021. URL: <https://www.elibrary.imf.org/display/book/9781513595603/ch002.xml>
45. BDO Italia S.p.A. Independent Auditors' Report on the Financial Figures and Reserves Report as of September 30, 2025 / Tether Holdings Limited. 2025. URL: <https://tether.to/en/transparency/#reports>
46. World Federation of Exchanges. Monthly Reports and Statistics. 2026. URL: <https://www.world-exchanges.org/our-work/statistics>

ПРИЛОЖЕНИЕ А

Таблица факторов после первичного отбора

№	Блок факторов	Обозначение переменной	Экономическая интерпретация	длина горизонта прогноза в минутах		
				10	20	30
1	Доходность ADA	ada_log_return_lag_1	Лог-доходность ADA за последнюю завершённую минуту	да	да	да
2	Доходность ADA	ada_log_return_lag_2	Лог-доходность ADA с лагом 2 минуты	да	да	да
3	Доходность ADA	ada_log_return_lag_3	Лог-доходность ADA с лагом 3 минуты	да	да	да
4	Доходность ADA	ada_log_return_lag_5	Лог-доходность ADA с лагом 5 минут	да	да	да
5	Доходность ADA	ada_log_return_lag_10	Лог-доходность ADA с лагом 10 минут	да	да	да
6	Накопленная доходность ADA	ada_cum_return_30m	Накопленная лог-доходность ADA за 30 минут	да	да	да
7	Накопленная доходность ADA	ada_cum_return_60m	Накопленная лог-доходность ADA за 60 минут	да	да	да
8	Ускорение доходности ADA	ada_return_acceleration_3m	Разность текущей минутной доходности ADA и доходности с лагом 3 минуты	да	да	да
9	Ускорение доходности ADA	ada_return_acceleration_5m	Разность текущей минутной	да	да	нет

			доходности ADA и доходности с лагом 5 минут			
10	Ускорение доходност и ADA	ada_return_acceleration_30m	Разность текущей минутной доходности ADA и доходности с лагом 30 минут	да	да	да
11	Эффективн ость движения ADA	ada_kaufman_efficiency_5m	Коэффициент эффективности Кауфмана для цены ADA за 5 минут	да	да	да
12	Эффективн ость движения ADA	ada_kaufman_efficiency_90m	Коэффициент эффективности Кауфмана для цены ADA за 90 минут	да	да	да
13	Отклонени е цены ADA	ada_close_zscore_30m	Z-оценка цены закрытия ADA относительно окна 30 минут	да	да	да
14	Отклонени е цены ADA	ada_close_zscore_90m	Z-оценка цены закрытия ADA относительно окна 90 минут	да	да	да
15	Волатильн ость ADA	ada_return_std_20m	Стандартное отклонение минутных лог- доходностей ADA за 20 минут	да	да	да
16	Волатильн ость ADA	ada_return_std_60m	Стандартное отклонение минутных лог- доходностей ADA за 60 минут	да	да	да
17	Реализован ная	ada_realized_volatility_5m	Реализованная волатильность ADA за 5 минут	да	не т	не т

	волатильность ADA					
18	Реализованная волатильность ADA	ada_realized_volatility_20m	Реализованная волатильность ADA за 20 минут	да	да	да
19	Реализованная волатильность ADA	ada_realized_volatility_60m	Реализованная волатильность ADA за 60 минут	да	да	да
20	Геометрия свечи ADA	ada_upper_wick_5m	Доля верхней тени синтетической свечи ADA за 5 минут	да	да	да
21	Геометрия свечи ADA	ada_upper_wick_30m	Доля верхней тени синтетической свечи ADA за 30 минут	да	нет	да
22	Геометрия свечи ADA	ada_upper_wick_60m	Доля верхней тени синтетической свечи ADA за 60 минут	нет	да	нет
23	Геометрия свечи ADA	ada_lower_wick_5m	Доля нижней тени синтетической свечи ADA за 5 минут	да	да	да
24	Геометрия свечи ADA	ada_lower_wick_60m	Доля нижней тени синтетической свечи ADA за 60 минут	да	да	да
25	Геометрия свечи ADA	ada_log_range_20m	Логарифмический диапазон high/low синтетической свечи ADA за 20 минут	да	да	да
26	Геометрия свечи ADA	ada_log_range_60m	Логарифмический диапазон high/low	да	да	да

			синтетической свечи ADA за 60 минут			
27	Геометрия свечи ADA	ada_close_position_10m	Положение цены закрытия ADA внутри диапазона свечи за 10 минут	да	да	да
28	Геометрия свечи ADA	ada_close_position_30m	Положение цены закрытия ADA внутри диапазона свечи за 30 минут	да	да	да
29	Геометрия свечи ADA	ada_close_position_60m	Положение цены закрытия ADA внутри диапазона свечи за 60 минут	да	да	да
30	Геометрия свечи ADA	ada_high_close_ratio_20m	Доля минут, закрывшихся в верхней части диапазона, за 20 минут	да	да	да
31	Геометрия свечи ADA	ada_high_close_ratio_60m	Доля минут, закрывшихся в верхней части диапазона, за 60 минут	да	да	да
32	Объем торгов ADA	ada_volume_sum_10m	Суммарный базовый объем торгов ADA за 10 минут	да	да	да
33	Объем торгов ADA	ada_volume_sum_20m	Суммарный базовый объем торгов ADA за 20 минут	да	не т	не т
34	Объем торгов ADA	ada_volume_sum_30m	Суммарный базовый объем торгов ADA за 30 минут	не т	да	не т

35	Объем торгов ADA	ada_volume_sum_60m	Суммарный базовый объем торгов ADA за 60 минут	нет	нет	да
36	Объем торгов ADA	ada_volume_zscore_60m	Z-оценка текущего объема ADA относительно окна 60 минут	да	да	да
37	Количество сделок ADA	ada_trades_per_minute_5m	Среднее число сделок ADA в минуту за окно 5 минут	да	да	да
38	Количество сделок ADA	ada_trades_per_minute_30m	Среднее число сделок ADA в минуту за окно 30 минут	да	да	да
39	Поток сделок ADA	ada_aggression_delta_norm_5m	Нормированный дисбаланс агрессивных покупок и продаж ADA за 5 минут	да	да	да
40	Поток сделок ADA	ada_aggression_delta_norm_10m	Нормированный дисбаланс агрессивных покупок и продаж ADA за 10 минут	нет	да	нет
41	Поток сделок ADA	ada_aggression_delta_norm_20m	Нормированный дисбаланс агрессивных покупок и продаж ADA за 20 минут	да	да	да
42	Поток сделок ADA	ada_large_trade_aggression_delta_norm_5m	Нормированный дисбаланс крупных агрессивных сделок ADA за 5 минут	да	да	да
43	Поток сделок ADA	ada_large_trade_aggression_delta_norm_20m	Нормированный дисбаланс крупных	да	да	да

			агрессивных сделок ADA за 20 минут			
44	Поток сделок ADA	ada_volume_entropy_norm_5m	Нормированная энтропия распределения объема сделок ADA за 5 минут	да	да	да
45	Поток сделок ADA	ada_inverse_simpson_norm_30m	Нормированный обратный индекс Симпсона для концентрации объема сделок ADA за 30 минут	да	да	да
46	Поток сделок ADA	ada_average_trade_size_quote_10m	Средний размер сделки ADA в котируемой валюте за 10 минут	да	да	да
47	Поток сделок ADA	ada_average_trade_size_quote_30m	Средний размер сделки ADA в котируемой валюте за 30 минут	да	да	да
48	Поток сделок ADA	ada_pressure_concentration_5m	Концентрация давления потока сделок ADA в конце окна 5 минут	да	да	да
49	Поток сделок ADA	ada_pressure_concentration_30m	Концентрация давления потока сделок ADA в конце окна 30 минут	да	да	да
50	Рыночный фон BTC	btc_log_return_30m	Лог-доходность BTC за 30 минут	да	да	да
51	Рыночный фон BTC	btc_log_return_60m	Лог-доходность BTC за 60 минут	да	да	да

52	Рыночная волатильность BTC	btc_return_std_30m	Стандартное отклонение минутных лог- доходностей BTC за 30 минут	да	да	да
53	Эффективн ость движения BTC	btc_kaufman_efficiency_60m	Коэффициент эффективности Кауфмана для цены BTC за 60 минут	да	да	да
54	Календарн ые признаки	time_of_day_sin	Синусоидально е кодирование времени суток	да	да	да
55	Календарн ые признаки	time_of_day_cos	Косинусоидаль ное кодирование времени суток	да	да	да
56	Календарн ые признаки	day_of_week_sin	Синусоидально е кодирование дня недели	да	да	да
57	Календарн ые признаки	day_of_week_cos	Косинусоидаль ное кодирование дня недели	да	да	да
58	Календарн ые признаки	is_weekend	Индикатор выходного дня	да	да	да
61	Торговые сессии	is_europe_open	Индикатор открытой европейской торговой сессии	да	да	да
62	Торговые сессии	is_us_open	Индикатор открытой торговой сессии США	да	да	да

ПРИЛОЖЕНИЕ Б

Разбиение признаков на подгруппы

Этап	Подгруппа	Признаки
1	AR(1)	ada_log_return_lag_1
1	AR(3)	ada_log_return_lag_1, ada_log_return_lag_2, ada_log_return_lag_3

1	AR(5)	ada_log_return_lag_1, ada_log_return_lag_2, ada_log_return_lag_3, ada_log_return_lag_5
1	AR(10)	ada_log_return_lag_1, ada_log_return_lag_2, ada_log_return_lag_3, ada_log_return_lag_5, ada_log_return_lag_10
1	Все лаги	ada_log_return_lag_1,2,3,5,10,15,30,60
2	Накопленная доходность	ada_cum_return_30m, ada_cum_return_60m
2	Ускорение доходности	ada_return_acceleration_3m,5m,30m
2	Эффективность тренда (Kaufman)	ada_kaufman_efficiency_5m,90m
2	Отклонение цены	ada_close_zscore_30m,90m
2	Волатильность	ada_return_std_20m,60m; ada_realized_volatility_5m,20m,60m
2	Тренд + волатильность	Объединение trend + volatility
2	Тренд + волатильность + эффективность	trend_volatility + efficiency
2	Геометрия свечей	upper/lower wick, log_range, close_position, high_close_ratio
2	Все ценовые признаки	Все признаки блока
3	Объем	volume_sum, volume_zscore
3	Число сделок	trades_per_minute
3	Агрессия участников	aggression_delta, large_trade_aggression_delta
3	Концентрация торговли	volume_entropy, inverse_simpson, pressure_concentration
3	Средний размер сделки	average_trade_size_quote
3	Объем + сделки	volume_only + trades_only
3	Агрессия + концентрация	aggression_only + concentration_only
3	Все микроструктурн ые признаки	Все признаки блока
4	Доходность BTC	btc_log_return_30m,60m
4	Волатильность BTC	btc_return_std_30m
4	Эффективность BTC	btc_kaufman_efficiency_60m

4	Доходность + волатильность BTC	returns + volatility
4	Все признаки BTC	returns + volatility + efficiency
5	Время суток	time_of_day sin, cos
5	День недели	day_of_week sin, cos, is_weekend
5	Торговые сессии	Asia, Europe, US, CBOE Europe
5	Время суток + сессии	time_of_day + sessions
5	День недели + сессии	day_of_week + sessions
5	Все календарные признаки	Все признаки блока